

بسم الله الرحمن الرحيم



دانشگاه شهید بهشتی

پژوهشکده فضای مجازی

ارائه روشی برای تشخیص جعل تصویر چهره بر پایه یادگیری بدون نمونه

پایان نامه کارشناسی ارشد فناوری اطلاعات گرایش چند رسانه‌ای

سید مصطفی حسینی کشکوئیه

استاد راهنما

دکتر احمد محمودی ازناوه



دانشگاه شهید بهشتی
پژوهشکده فضای مجازی

پایان نامه کارشناسی ارشد – آقای سید مصطفی حسینی کشکوئی
تحت عنوان
ارائه روشی برای تشخیص جعل تصویر چهره بر پایه یادگیری بدون نمونه

در تاریخ توسط کمیته‌ی تخصصی زیر مورد بررسی و تصویب نهایی قرار گرفت:

۱ - استاد راهنمای پایان نامه دکتر

۳ - استاد داور دکتر

۴ - استاد داور دکتر

سرپرست تحصیلات تکمیلی دانشکده دکتر

تشکر و قدردانی

پروردگار منان را سپاسگزارم.

کلیه حقوق مالکیت مادی و معنوی مربوط
به این پایان نامه متعلق به دانشگاه شهید
بهشتی و پدیدآورندگان است. این حقوق
توسط دانشگاه شهید بهشتی و بر اساس
خط مشی مالکیت فکری این دانشگاه،
ارزش گذاری و سهم بندی خواهد شد. هر
گونه بهره برداری از محتوا، نتایج یا اقدام
برای تجاری سازی دستاوردهای این پایان
نامه تنها با مجوز کتبی دانشگاه شهید بهشتی
امکان پذیر است.

فهرست مطالب

عنوان	صفحه
فهرست مطالب	هفت
فهرست تصاویر	نه
فهرست جداول	ده
چکیده	۱
فصل اول: مقدمه	۲
۱-۱ صورت مسئله	۳
۲-۱ اهداف پژوهش	۳
۳-۱ نوآوری پژوهش	۴
۴-۱ ساختار پایان نامه	۴
فصل دوم: یادگیری با نمونه	۵
۱-۲ مدل	۶
۲-۲ دادگان	۸
۳-۲ سخن پایانی	۹
فصل سوم: کارهای مرتبط	۱۰
۱-۳ مقدمه	۱۰
۲-۳ دسته‌بندی کلی	۱۳
۱-۲-۳ فضاهای مهندسی شده	۱۳
۲-۲-۳ فضاهای یادگرفته شده	۱۴
۳-۲-۳ روش‌های بر پایه دسته‌بند	۱۶
۴-۲-۳ روش‌های بر پایه نمونه	۱۷
۳-۳ یک مثال	۱۹
۱-۳-۳ روش مستقیم	۲۱
۲-۳-۳ روش غیر مستقیم	۲۱
۳-۳-۳ بانک‌های اطلاعاتی	۲۳

۲۴	ارزیابی ۴-۳-۳
۲۶	نتیجه ۵-۳-۳
۲۷		فصل چهارم: روش پیشنهادی
۲۸		فصل پنجم: پیاده‌سازی
۲۹		فصل ششم: ارزیابی کارایی
۳۰		فصل هفتم: جمع‌بندی و نتیجه‌گیری
۳۱	مراجع

فهرست تصاویر

۷	۱-۲ شبکه ساده سیامی برای دسته بند دودویی [۱]
۷	۲-۲ یک نیمه از شبکه دو قلو استفاده شده [۱]
۸	۳-۲ دادگان اعوجاج داده شده [۱]
۱۲	۱-۳ نحوه دسته بندی تصاویر توسط مدل ارائه شده [۲]
۲۰	۲-۳ روش های دسته بندی [۲]
۲۵	۳-۳ منحنی ROC [۲]

فهرست جداول

۱-۲	دقت مرحله تایید در سه دسته انتخاب دادگان [۱]	۸
۲-۲	مقایسه روش های مختلف [۱]	۹
۳-۲	مقایسه با ۱NN [۱]	۹
۱-۳	بانک های اطلاعاتی [۲]	۲۴
۲-۳	تقسیم بندی پیش فرض داده ها [۲]	۲۴
۳-۳	تقسیم بندی داده ها به صورت تصادفی [۲]	۲۴
۴-۳	تقسیم بندی پیش فرض داده ها برای aPascal-aYahoo [۲]	۲۶
۵-۳	تقسیم بندی داده ها برای attributes sub [۲]	۲۶

چکیده

جمع آوری داده و پرچسب زدن داده‌ها از مهم‌ترین مراحل پیش‌پردازش در یادگیری ماشین است. اما همواره جمع‌آوری به سادگی نیست و ما به داده‌های برچسب‌خورده دسترسی نداریم. عدم دسترسی به دادگان مناسب، هزینه زیاد جمع آوری دادگان و مشاهده نمونه‌های جدید از عوامل حرکت به سمت یادگیری با نمونه کم، یک نمونه و در نهایت بدون نمونه بوده‌اند.

در سیستم‌های تشخیص چهره، یکی از ارکان اساسی برای سلامت و کارایی سیستم توانایی جلوگیری از حملات مختلف و تشخیص جعل تصویر است. راهکارها و روش‌های بسیاری در طول سالیان مخلف ارائه شده است؛ اما نکته حائز اهمیت تغییر کردن و به‌روز شدن حملات است که باعث می‌شود این کشمکش بین حملات و سیستم‌های تشخیص حملات و جعل تصاویر همواره وجود داشته باشد.

از روش‌های پر کاربردی که برای تولید تصاویر جعلی و انجام حملات به سیستم‌های تشخیص چهره استفاده می‌شود روش‌های تخصمی و استفاده از شبکه‌های متولد متخاصم است. جلوگیری از این حملات و نیازمند روش‌های هوشمند و به‌روزی است به همین به سراغ استفاده از روش یادگیری بدون نمونه رفته‌ایم تا بتوانیم با استفاده از آن از حملات جلوگیری کنیم و جعل تصویر چهره را تشخیص دهیم.

واژه‌های کلیدی: ۱- یادگیری ماشین ۲- جعل تصویر چهره ۳- شبکه‌های مولد تخصمی ۴- یادگیری بدون نمونه

فصل اول

مقدمه

تشخیص چهره یکی از روش‌های احراز هویت بیومتریک^۱ است که در قدیم توسط سیستم‌های امنیتی پیشرفته انجام می‌شد. در روش‌های بیومتریک از اثر انگشت یا کل دست، عنبیه چشم، صدا، چهره و غیره استفاده می‌شود که متداول‌ترین آن استفاده از چهره فرد است. امروزه با توجه به پیشرفت تکنولوژی و همه‌گیر شدن آن تشخیص چهره را در گوشی‌های هوشمند همراه می‌توان یافت.

همه‌گیری این تکنولوژی باعث پیشرفت‌های فراوان آن نیز شده است و امروزه گوشی‌های همراه می‌توانند به سرعت و با دقت بالا تشخیص چهره را انجام دهند و تقریباً به بهترین شکل اینکار را انجام می‌دهند. اما به امنیت این سیستم‌ها به اندازه کافی توجه نشده است. به این سیستم‌ها حملات متعددی صورت می‌گیرد که می‌توانند باعث خرابی سیستم، جعل هویت و یا گرفتن دسترسی کامل توسط حمله‌کننده و هکرها شود. این سیستم‌ها به طور عمده

^۱biometric authentication

امروزه بر اساس شبکه‌های عصبی عمیق یا DNN^۱ و شبکه‌های عصبی کانولوشن یا CNN^۲ ساخته می‌شوند. در مقالات زیادی انواع حملات به این نوع شبکه‌ها بررسی شده‌اند.

تشخیص حملات و مقابله با آن‌ها یکی از مواردی است که باید به آن توجه ویژه‌ای داشت. یکی از مشکلات اساسی در حملات و جعل تصاویر صورت گرفته دسته‌بندی حملات و تشخیص نوع حمله است که به آسانی توسط انسان امکان‌پذیر نیست.

۱-۱ صورت مسئله

تشخیص و دسته‌بندی حملات به سیستم‌های تشخیص چهره و جعل تصاویر چهره از بزرگ‌ترین معزلات توسعه دهندگان این سیستم‌هاست. تضمین امنیت سیستم برای جلوگیری از دور زدن سیستم، گرفتن دسترسی‌های بیشتر و یا احراز هویت به جای فرد دیگری توسط هکرها از مواردی است که توسعه دهندگان باید مد نظر داشته باشند. با توجه به اینکه به طور عمده حملات در دسته‌های مشخصی قرار می‌گیرند و ویژگی‌هایی دارند که می‌توان آن‌ها را دسته‌بندی کرد استفاده از روش‌های دسته‌بندی به شیوه‌های مختلف می‌تواند کارآمد و کمک‌کننده باشد.

برای دسته‌بندی باید بتوانیم ویژگی‌های حملات مختلف را تشخیص دهیم. تشخیص این ویژگی‌ها به سادگی تشخیص ویژگی‌های تصاویر حیوانات مختلف برای دسته‌بندی آن‌ها نیست و ویژگی‌ها پیچیده‌تر و نیازمند سیستم‌های تشخیص دقیق‌تری هستند. بعد از تشخیص ویژگی‌های مورد نظر می‌توان حمله را دسته‌بندی کرد و متناسب با نوع حمله با آن مقابله کرد.

۱-۲ اهداف پژوهش

تجربه نشان داده است که یادگیری بدون نمونه برای دسته‌بندی و تشخیص نمونه‌هایی که کمتر تا کنون دیده شده‌اند یا اصلاً دیده نشده‌اند، موفق عمل کرده و توانسته دسته‌بندی را به نحو احسن انجام دهد. استفاده از

^۱Deep Neural Networks

^۲Convolutional Neural Network

یادگیری بدون نمونه در مواردی که پیدا کردن ویژگی‌های مشترک مانند حیوانات و اشیاء پیرامون به سادگی نیست و نمی‌توان فهرستی از ویژگی‌های مشترک را به آسانی تهیه کرد؛ موفق عمل کرده است. هدف پژوهش استفاده از دادگان‌های موجود و پر کاربرد در حوزه جعل تصویر چهره و یادگیری بدون نمونه برای ارائه راهکاری که قابلیت تشخیص و دسته‌بندی حملات مختلف به سیستم‌های تشخیص چهره را با دقتی نزدیک به دقت تشخیص چهره دارد، است.

۱-۳ نوآوری پژوهش

۱-۴ ساختار پایان‌نامه

در فصل دوم، به بررسی اجمالی درباره یادگیری بدون نمونه و انواع آن می‌پردازیم و همچنین حملات و جعل‌های مختلف تصویر چهره را بررسی می‌کنیم. در فصل سوم، کارهای مرتبط به این پژوهش بررسی می‌شوند و مزایا و معایب آن‌ها به طور مختصر بررسی می‌گردد. در فصل چهارم، به تفصیل روش پیشنهادی و ایده اصلی بیان شده است. نحوه پیاده‌سازی و ساختار مدل بررسی شده است. در فصل ششم نتایج و ارزیابی‌های مرتبط بررسی شده و میزان کارایی و نتایج به دست آمده مورد تحلیل قرار گرفته است و در نهایت در فصل هفتم جمع‌بندی پایانی صورت گرفته است.

فصل دوم

یادگیری با نمونه

همانطور که در پیش‌گفتار بحث شد، فرآیند یادگیری نیازمند نمونه‌داده‌هایی است که بتوانیم به وسیله آن‌ها مدل را آموزش دهیم و بتوانیم داده‌های جدید را دسته‌بندی کنیم. در این فصل روش‌هایی که برای دسته‌بندی داده‌های جدید به نمونه نیاز دارند بررسی می‌شوند و یک مثال از یادگیری با یک نمونه برای فهم بهتر مبحث آورده شده‌است. در یادگیری به صورت سنتی، باید داده‌ها با دو دسته آموزش و آزمون تقسیم‌بندی شوند و برای هر کلاس جدید برای دسته‌بندی باید به تعداد کافی داده وجود داشته باشد تا مدل بتواند دسته‌بندی مناسبی انجام دهد. مانند مدل کانولوشن ساده‌ای که با آن می‌توان سگ و گربه را از هم تفکیک داد. این مدل برای هر داده سگ و گربه باید تعداد قابل توجهی داده دیده باشد تا بتواند دسته‌بندی را به درستی انجام دهد. حال برای دسته‌بندی یک حیوان دیگر توسط این مدل باید داده‌های جدیدی به مدل بدهیم تا مدل بتواند آن نوع حیوان را نیز دسته‌بندی کند. با بهبود ساختار شبکه یادگیرنده می‌توان نیاز فرآیند یادگیری به داده‌های زیاد را کاهش داد تا مدل بتواند با

داده‌های کم نیز دسته‌بندی را انجام دهد. ارائه راهکارها و روش‌هایی در کنار استفاده از شبکه‌های عصبی این امکان را به وجود آورد تا مدل فقط با دیدن یک نمونه از یک کلاس داده در فرآیند آموزش بتواند داده جدید را دسته‌بندی کند. این روش با نام یادگیری با یک نمونه شناخته می‌شود.

در این روش در فرآیند آموزش مدل به حداقل یک داده از یک کلاس داده نیاز دارد. برای جلوگیری از بیش‌برازش^۱ در فرآیند آموزش از روش‌هایی مانند ایجاد اعوجاج در داده‌ها برای تولید داده جدید در حالات مختلف استفاده می‌شود تا مدل بتواند دسته‌بندی بهتری انجام دهد. فرآیند یادگیری با یک نمونه در مواردی پر کاربرد تر است که ما تمامی کلاس‌های داده را از قبل داشته باشیم؛ برای مثال: در مبحث پردازش زبان طبیعی انسان، ساختار هر زبان مشخص است و زبان‌ها از یکدیگر با ساختارهای مشخص قابل تفکیک هستند و هر زبان تعداد ثابتی قواعد و واژگان دارد. این قابلیت به ما کمک می‌کند تا بتوانیم از مدل یادگیری با یک نمونه برای کاربرد پردازش زبان طبیعی استفاده کنیم. با یک مثال و بررسی یک ساختار شبکه ارائه شده در یک مقاله به بررسی بیشتر این موضوع می‌پردازیم.

زبان سیامی یکی از زبان‌های آسیایی است و ساختار مشخص و واژگان ثابتی را دارد. در ادامه قصد داریم با معرفی یک مدل بتوانیم واژگان دست‌نویس این زبان را تفکیک و دسته‌بندی کنیم.

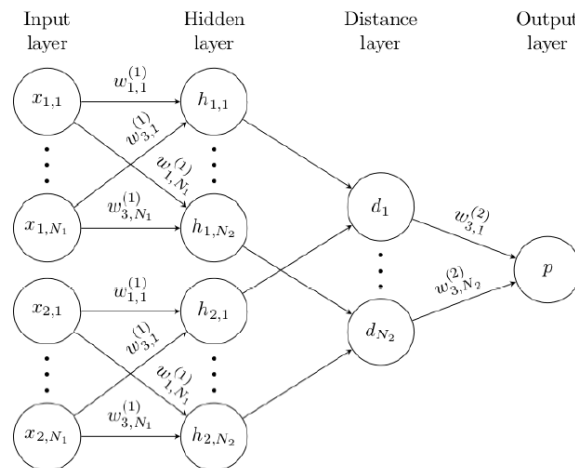
۱-۲ مدل

مدل به صورت یک شبکه عصبی دو قلو است. برای دسته‌بندی این شبکه دوتایی‌های مشابه و مخالف را ایجاد می‌کند. یعنی با استفاده از شباهت‌ها و تفاوت‌های موجود درون کاراکترهای زبان آن‌ها را دسته‌بندی می‌کند در انتها هنگام دریافت نمونه جدید شبکه شباهت و تفاوت‌های این نمونه با نمونه‌های موجود را تشخیص می‌دهد و آن را در یک دسته قرار می‌دهد.

برای محاسبه تفاوت و شباهت یک معیار فاصله وزن دار L_1 بین بردارهای ویژگی استخراج شده از دو شبکه

¹over fitting


دو قلو استفاده کرده و بر اساس آن نرخ یادگیری شبکه و نحوه دسته‌بندی واژگان را مشخص کرده‌است. در شکل ۲-۱ یک نمونه ساده از این شبکه برای دسته‌بندی دودویی را مشاهده می‌کنید.



شکل ۲-۱: شبکه ساده سیامی برای دسته‌بندی دودویی [۱]

همانطور که گفتیم این شبکه ساختاری دو قلو دارد که بتواند یک زوج مشابه یا متفاوت را دسته‌بندی کند.

ساختار یک نیمه از این شبکه را در شکل ۲-۲ مشاهده می‌کنید.



شکل ۲-۲: یک نیمه از شبکه دو قلو استفاده شده [۱]

با توجه به اینکه دادگان کمی برای آموزش در اختیار است، برای جلوگیری از بیش‌برازش داده‌های موجود در

حالات مختلف اعوجاج داده شده‌اند. اعوجاج داده این کمک را می‌کند تا با نمونه‌های حتی اندک هم بتوانیم

دسته‌بندی مناسبی ارائه کنیم. ۲-۳



شکل ۲-۳: دادگان اعوجاج داده شده [۱]

۲-۲ دادگان

دادگان استفاده شده Omniglot است. این دادگان شامل نمونه‌هایی از ۵۰ الفبای مختلف است. به سه صورت همانطور که در جدول ۱-۲ مشاهده می‌کنید از این دادگان استفاده شده‌است و دقت مرحله تایید^۱ را در جدول آورده است.

جدول ۱-۲: دقت مرحله تایید در سه دسته انتخاب دادگان [۱]

Test	Method
	30k training
۶۱.۹۰	<i>no</i> distortions
۹۰.۹۱	affine distortions x8
	90k training
۵۴.۹۱	<i>no</i> distortions
۱۵.۹۳	affine distortions x8
	150k training
۶۳.۹۱	<i>no</i> distortions
۴۲.۹۳	affine distortions x8

در مقایسه با این روش، روش‌های دیگری نیز تعریف شده‌اند که صرف نظر از دقت انسان بهترین آن‌ها مدل بر پایه روابط احتمالاتی و در رتبه بعد این روش جزو بهترین روش‌های ارائه شده برای دسته‌بندی واژگان است. روش‌های دیگر در ۲-۲

در پایان برای نشان دادن قدرت شبکه و عام بودن استفاده از آن، دادگان MNIST انتخاب شده است و بر روی این دادگان که حاوی کاراکترهای دست‌نویس است این مدل با مدل 1-nearest neighbor مقایسه شده است، دقت بسیار بالاتری را کسب کرده است اما برای این دادگان کافی نیست و هدف نشان دادن این بوده‌است که

^۱verification

جدول ۲-۲: مقایسه روش‌های مختلف [۱]

Test	Method
۵.۹۵	Humans
۲.۹۵	Hierarchical Bayesian Program Learning
۸.۸۱	Affine model
۲.۶۵	Hierarchical Deep
۰.۶۲	Deep Boltzmann Machine
۲.۳۵	Simple Stroke
۷.۲۱	1-Nearest Neighbor
۳.۵۸	Siamese Neural Net
۰.۹۲	Convolutional Siamese Net

این روش و شبکه را می‌توان با اصلاحاتی برای استفاده‌های دیگر نیز طراحی و آماده کرد. همان‌طور که در جدول ۲-۳ مشاهده می‌کنید روش یادگیری با یک نمونه به راحتی قابل تعمیم است و می‌توان از آن برای حل مسائل مختلف استفاده کرد.

جدول ۲-۳: مقایسه با ۱NN [۱]

Test	Method
۵.۲۶	1-Nearest Neighbor
۳.۷۰	Convolutional Siamese Net

۲-۳ سخن پایانی

در این فصل سعی شد تلاش صورت گرفته برای کاهش وابستگی مدل به داده و یادگیری با نمونه و انواع آن را با بررسی یک مقاله در حوزه یادگیری با یک نمونه توضیح دهیم.

فصل سوم

کارهای مرتبط

۱-۳ مقدمه

در یادگیری بدون نمونه ما با دو نوع داده سروکار داریم. داده‌های دیده‌شده که برای آموزش مدل از آن‌ها استفاده می‌کنیم و داده‌های دیده‌نشده که مدل آموزش دیده شده باید بتواند آن‌ها را دسته‌بندی کند. داده‌های دیده‌شده، داده‌هایی برچسب خورده هستند و یک سری ویژگی‌های مشخص دارند. مدل آموزش دیده بر اساس این داده‌ها باید بتواند داده‌های دیده‌نشده را بر اساس ویژگی‌های استخراج کرده و ویژگی‌های داده‌های قبل، داده‌های جدید را دسته‌بندی کند.

فرآیند یادگیری و بررسی مدل، دو فرآیند جدا از هم هستند و داده‌های دیده‌شده و دیده‌نشده با یکدیگر اشتراکی ندارند بر این اساس می‌توان از روش یادگیری انتقالی برای یادگیری مدل‌های بر پایه یادگیری بدون نمونه استفاده کرد. در یادگیری انتقالی مدل یکبار با استفاده از داده‌های مناسب وزن‌دهی و مقداردهی شده است، حال کافی

است مدل آماده را برای تشخیص داده‌های جدید یا در روش‌های دیگر برای فعالیت‌های دیگر به کار گرفت و نیاز نیست تا دوباره از ابتدا فرآیند یادگیری را از سر بگیریم. فرآیند یادگیری انتقالی مانند نوزاد انسان است که در ابتدا درباره محیط اطراف اطلاعات کمی دارد اما کم کم از محیط یاد می‌گیرد و از تجربیات قبلی در یادگیری‌های بعدی نیز استفاده می‌کند.

چند حالت کلی رایج وجود دارد که استفاده از یادگیری بدون نمونه در این موارد به ما کمک می‌کند:

- وقتی فضای هدف به قدری بزرگ هست که همواره نمی‌توان تمامی حالات ممکن را پوشش داد؛ برای مثال: در تشخیص اشیا اطراف همواره اشیا جدید وجود دارد که در یک دسته‌بندی جدا قرار می‌گیرد.
- ممکن است نمونه‌های کلاس هدف کم‌یاب باشند و به سادگی به آن‌ها دسترسی نداشته باشیم؛ برای مثال: در تشخیص گونه‌های مختلف یک گیاه ممکن است همواره گونه‌های جدیدی پیدا شوند که تا به حال دیده نشده‌اند و یا گونه‌هایی باشند که دسترسی به آن‌ها دشوار است.
- ممکن است نمونه‌های کلاس هدف در طول زمان دچار تغییر شوند؛ مانند: نمونه‌های برندهای مختلف پوشاک
- ممکن است داده وجود داشته‌باشد اما فرآیند برچسب گذاری هزینه‌بر باشد.

با توجه به اینکه داده‌های کلاس هدف را تا کنون ندیده‌ایم، نیاز به یک سری اطلاعات جانبی^۱ داریم تا بتوانیم ارتباطی بین داده‌های آموزش و داده‌های هدف پیدا کنیم. اطلاعات جانبی باید در فضای ویژگی مرتبط با نمونه‌ها باشند تا بتوانیم به عنوان اطلاعات مناسب از آن‌ها استفاده کنیم؛ به طور مثال: در مسئله تشخیص حیوانات در صورتی که مدل ما اسب و ببر را دیده باشد می‌تواند آن‌ها را دسته‌بندی کند. حال اگر یک نمونه تصویر گورخر به مدل نشان دهیم با توجه به اینکه تاکنون مدل آن را ندیده‌است باید بتوانیم با روشی به مدل بفهمانیم تا بتواند

^۱auxiliary information

آن را نیز دسته‌بندی کند. گورخر جثه‌ای شبیه به اسب و طرحی شبیه به ببر دارد؛ این‌ها اطلاعات جانبی است که با استفاده از آن‌ها می‌توانیم بین داده‌های کلاس آموزش و هدف ارتباط برقرار کنیم. نمونه استفاده از اطلاعات جانبی در دسته‌بندی را می‌توانید در شکل ۳-۱ مشاهده کنید.

اطلاعات جانبی مورد استفاده به طور معمول یکسری اطلاعات معنایی هستند. این اطلاعات کمکی در یک فضای جدید (فضای معنایی^۱) شامل هر دو دسته کلاس‌های دیده‌شده و دیده‌نشده می‌شوند. فضای معنایی نیز مانند فضای ویژگی یک فضای چند بعدی است. در فضای معنایی هر کلاس با یک توصیف برداری شناخته می‌شود که به این توصیف برداری، ضابطه کلاس^۲ گویند.

otter

black: yes
white: no
brown: yes
stripes: no
water: yes
eats fish: yes

polar bear

black: no
white: yes
brown: no
stripes: no
water: yes
eats fish: yes

zebra

black: yes
white: yes
brown: no
stripes: yes
water: no
eats fish: no

otter

black: yes
white: no
brown: yes
stripes: no
water: yes
eats fish: yes

polar bear

black: no
white: yes
brown: no
stripes: no
water: yes
eats fish: yes

zebra

black: yes
white: yes
brown: no
stripes: yes
water: no
eats fish: no



شکل ۳-۱: نحوه دسته‌بندی تصاویر توسط مدل ارائه شده [۲]

¹semantic space

²class prototype

۲-۳ دسته‌بندی کلی

به طور کلی مقالات حوزه یادگیری بدون نمونه به دو طریق بر اساس تفاوت‌های فضای معنایی و بر اساس تفاوت روش‌های استفاده شده بررسی شده‌اند. فضاهای استفاده شده در دو دسته مهندسی شده^۱ و فضاهای یادگرفته شده^۲ و روش‌ها در دو دسته بر پایه دسته‌بند^۳ و بر پایه نمونه^۴ بررسی می‌شوند. [۳]

۱-۲-۳ فضاهای مهندسی شده

فضاهای مهندسی شده توسط متخصصان طراحی و متناسب با کاربرد مورد نظر استفاده شده‌اند. نمونه‌های پر کاربرد آن‌ها می‌توان به فضای مشخصه^۵، لغوی^۶ و متنی-کلیدواژه‌ها^۷ اشاره کرد که هر یک را مختصر توضیح می‌دهیم.

فضای مشخصه

بر اساس یک سری مشخصه‌ها ساخته شده‌اند. مشخصه‌ها ویژگی‌های سطح بالایی هستند که برای انسان یک معنا و مفهومی را تداعی می‌کنند؛ مانند: رنگ پوست، نوع زیست و محیط زندگی. این ویژگی‌ها را نمی‌توان همانند ویژگی‌های سطح پایین مانند شکل و فرم کلی بدن با استفاده از شبکه‌های عصبی کانولوشنی یاد گرفت. کاربرد این مشخصه‌ها در انتقال یادگیری است. زیرا ویژگی‌های سطح پایین برای انتقال یادگیری در یادگیری بدون نمونه ارزش چندانی ندارند. این نوع از فضا به چند دسته تقسیم بندی می‌شود: دودویی، پیوسته و نسبی.

فضای مشخصه دودویی شامل مشخصه‌هایی است که فقط یک مقدار صفر و یا یک می‌توانند بگیرند؛ به طور مثال یک حیوان یا گیاه خوار است یا نیست و حد وسطی وجود ندارد. فضای مشخصه پیوسته شامل ویژگی‌هایی است که می‌توانند چندین مقدار بین صفر و یک بگیرند. در واقعیت مشخصه‌ها ویژگی‌هایی پیوسته هستند اما

¹Engineered

²Learned

³classifier-based

⁴instance-base

⁵Attribute

⁶lexical

⁷text-keywords

برای راحتی استفاده آنها را دودویی در نظر می‌گیریم. فضای مشخصه نسبی شامل ویژگی‌هایی است که بتوان با آنها ارتباطات بین کلاس‌ها را بهتر بیان کرد؛ برای مثال: خشک‌زی یا آب‌زی بودن و دو زیست بودن.

در مقاله [۲] برای دسته‌بندی حیوانات یک پایگاه داده با فضای مشخصه پایگاه داده^۱ معرفی شده است. که شامل بیش از ۳۰۰۰۰ تصویر حیوانات در ۵۰ دسته مختلف و ۸۵ ویژگی معنایی است. انسان قادر است تا حدود ۳۰۰۰۰ دسته پایه از چیزهای مختلف را تشخیص دهد. هدف بینایی ماشین همواره نزدیک کردن ماشین به انسان بوده است.

فضای لغوی

مجموعه لغاتی هستند که بر پایه برچسب کلاس‌ها و داده‌هایی اند که اطلاعات معنایی دارند. مجموعه لغات استفاده شده می‌تواند WordNet باشد و برای ایجاد رابطه می‌توان روابط خواهر-برادی، والد-فرزندی و یا هر رابطه قابل تعریف دیگری استفاده کرد.

فضای متن-کلیدواژه‌ها

این فضا بر اساس کلیدواژه‌ها ساخته شده‌اند. کلید واژه‌ها را می‌توان از هر منبعی یا سایتی مانند ویکی‌پدیا استخراج کرد. این کلیدواژه‌ها از توصیفاتی که درباره کلاس‌های مختلف وجود دارند استخراج می‌شوند. به طور خلاصه فضاهای مهندسی شده توسط افراد متخصص طراحی می‌شوند و می‌توانند انعطاف پذیر باشند و متناسب با فضای معنایی و قوانین دلخواه تولید شوند؛ اما نکته منفی در مورد آنها این است که وابسته به یک متخصص هستیم و تلاش انسانی زیادی برای تولید آنها باید صورت گیرد.

۳-۲-۲ فضاهای یادگرفته شده

این فضاها بر خلاف مدل قبلی توسط ماشین یاد گرفته شده‌اند. در این فضاها هر بعد به تنهایی نمی‌تواند بیانگر یک معنا و مفهوم باشد و ابعاد مختلف در کنار هم معنا پیدا می‌کنند. مدل‌های ماشینی استفاده شده برای یادگیری

^۱ Animals with Attributes-AwA

این فضاها می‌توانند مدل‌های از قبل آموزش دیده باشند یا می‌توان از پایه یک مدل را طراحی کرد. سه فضای پر کاربرد می‌توان به جایگذاری برچسب^۱، جایگذاری متن^۲ و نمایش تصویر^۳ اشاره کرد.

فضای جایگذاری برچسب

این فضا بر اساس روش جایگذاری کلمه در پردازش زبان طبیعی ساخته شده است. در این روش، کلمات در فضایی از اعداد حقیقی جایگذاری می‌شوند و در نتیجه یک بردار در فضای جایگذاری به ازای هر کلمه ایجاد خواهد شد. این فضا حاوی اطلاعات معنایی است و کلماتی که حاوی معنایی نزدیک و مشابه اند در نزدیکی یکدیگر قرار می‌گیرند. در یادگیری بدون نمونه برچسب هر کلاس یک کلمه است که می‌توان از این روش استفاده کرد.

فضای جایگذاری متن

این فضا شبیه به فضای متن - کلیدواژه در فضاها مهندسی شده است با این تفاوت که در این فضا ماشین ارتباطات و ضوابط بین کلاس‌ها و متون را پیدا خواهد کرد.

فضای نمایش تصویر

در این فضا برای هر کلاس تعدادی تصویر به عنوان نمونه انتخاب خواهد شد. این نمونه‌ها به یک ماشین، داده خواهد شد تا ارتباط بین تصاویر و کلاس‌های مورد نظر را پیدا کند و از آن طریق بردارهای خروجی را یافته و ضابطه کلاس‌ها را تشکیل دهد.

به طور خلاصه فضاها یادگرفته شده نیازی به یک انسان متخصص ندارند و می‌توانند ویژگی‌هایی را تولید کنند که شاید از دید متخصص پنهان بنمان که این می‌تواند یک برتری نسبت به فضای مهندسی شده باشد. از طرفی، این نکته که هر بعد این فضاها به تنهایی یک معنا و مفهوم مستقل ندارد می‌تواند یک نقطه ضعف در مقابل فضاها مهندسی شده باشد.

¹ Label-embedding

² Text-embedding

³ Image-representation

۳-۲-۳ روش‌های بر پایه دسته‌بند

هدف و تمرکز در این روش‌ها این است که از یک دسته‌بند برای تشخیص کلاس‌های دیده‌نشده استفاده کنیم. روش این دسته‌بندها یک در مقابل بقیه^۱، است که در این روش در هر تصمیم‌گیری برای کلاس دیده نشده یک مسئله دسته‌بندی دودویی وجود خواهد داشت. در حقیقت این روش‌ها یک سری دسته‌بند دودویی در کنار هم هستند. روش‌های ساخت دسته‌بندها در ادامه آورده شده‌است. این روش‌ها در سه دسته مبتنی بر تطابق^۲، مبتنی بر ارتباط^۳ و مبتنی بر ترکیب^۴ بررسی می‌شوند.

روش مبتنی بر تطابق

هدف، ساخت دسته‌بند با یافتن شباهت‌های موجود بین دسته‌بند یک در مقابل بقیه هر کلاس و ضابطه آن کلاس است. ضابطه هر کلاس یک نمایش و توصیفی از کلاس است و یافتن شباهت و تطابق بین آن و دسته‌بندی مربوط به آن کلاس به تولید دسته‌بند اصلی منجر می‌شود. برای داده‌های دیده نشده با استفاده از ضابطه کلاس و تابع تطابق یافت شده یک دسته‌بند ساخته می‌شود و کلاس جدید دسته‌بندی می‌شود.

نقطه قوت این روش ارتباطات بر پایه تابع تطابق است که به راحتی قابل یافتن است اما نقطه ضعف این روش این است که این ارتباطات را به طور صریح و واضح بیان نمی‌کند.

مبتنی بر ارتباط

هدف، ساخت دسته‌بند بر اساس ارتباط بین کلاس‌هاست. برای یافتن ارتباط میان کلاس‌های دیده‌شده و دیده‌نشده می‌توان از ارتباط بین ضابطه کلاس‌ها و یا هر ارتباط مناسب دیگری استفاده کرد. برای کلاس‌های دیده‌نشده با استفاده از ارتباط موجود و دسته‌بند کلاس‌های دیده‌شده یک دسته‌بند برای هر کلاس دیده‌نشده ساخته می‌شود. از دسته‌بندی کلاس‌های دیده‌شده می‌توان در مسائل دیگر نیز استفاده کرد و هزینه آموزش مدل را کاهش داد؛

¹ one versus rest

² Correspondence

³ Relationship

⁴ Combination

اما، روابط بین کلاس‌ها از فضای معنایی به فضای ویژگی به طور مستقیم منتقل می‌شود که حل مسئله سازگاری از فضای معنایی به فضای ویژگی مشکل است.

مبتنی بر ترکیب

در این روش هر کلاس را ترکیبی از چند عنصر در نظر می‌گیریم که این عناصر در فضای معنایی وجود دارند. در حقیقت برای استفاده باید از فضاهای دودویی استفاده کرد که فضاهای معمول استفاده شده فضاهای مهندسی شده هستند. روش ساخت دسته‌بند برای کلاس‌های دیده‌نشده بدین صورت است که برای هر یک از عناصر سازنده کلاس‌ها دسته‌بند ساخته شده است سپس از آن دسته‌بندها برای ساخت دسته‌بند کلاس جدید استفاده می‌کنیم. همانند روش قبل می‌توان از دسته‌بندی‌های مورد استفاده در مسائل دیگر نیز استفاده کرد؛ اما، بهینه سازی مسئله دو مرحله‌ای آموزش دسته‌بند مشخصه و استنتاج از مشخصه به کلاس دشوار است.

۴-۲-۳ روش‌های بر پایه نمونه

هدف در این روش‌ها ایجاد نمونه برچسب‌خورده برای کلاس‌های دیده نشده است. با استفاده از این نمونه‌ها دسته‌بند اصلی آموزش می‌بیند. با توجه به تفاوت در نحوه و منبع تولید نمونه، این روش‌ها به سه زیر دسته مبتنی بر تصویر کردن^۱، مبتنی بر قرض نمونه^۲ و مبتنی بر سنتز^۳ تقسیم می‌شوند.

مبتنی بر تصویر کردن

تولید نمونه برای کلاس دیده‌نشده از طریق تصویر کردن نمونه‌های موجود در فضای ویژگی و ضابطه‌های موجود در فضای معنایی، به یک فضای مشترک انجام می‌شود. در فضای ویژگی با استفاده از دسته‌بند می‌توان داده‌های آزمایش را دسته‌بندی کرد. این ویژگی‌ها فقط برای داده‌های آزمایشی موجود هستند. فضای معنایی شامل ضابطه‌هایی است که هم شامل داده‌های جدید و هم شامل داده‌های آزمایش می‌شوند. می‌بایست یک ارتباط بین

¹Projection

²Instance-borrowing

³Synthesizing

فضای ویژگی و فضای معنایی پیدا کنیم و با انتقال هر دو فضا و تصویر کردن در یک فضای سوم از ضابطه‌های موجود به عنوان نمونه کلاس‌های دیده نشده استفاده کنیم. با توجه به اینکه با این روش برای هر کلاس دیده نشده یک نمونه تولید می‌شود و فرآیند دسته‌بندی دشوار می‌شود می‌توان از روش‌های ناپارامتری مانند روش KNN استفاده کرد تا بتوان دسته‌بندی بهتری داشت.

انتخاب تابع نگاشت انعطاف پذیر است و با توجه به شرایط مسئله می‌توان دادگان مناسب انتخاب کرد؛ اما، چون برای هر کلاس دیده نشده یک نمونه برچسب زده وجود دارد ناچار به استفاده از روش‌های ناپارامتری می‌شویم.

مبتنی بر قرض نمونه

در این روش بر اساس شباهت‌های بین کلاس‌های دیده شده و دیده نشده برای کلاس‌های دیده نشده از کلاس‌های دیده شده نمونه قرض می‌گیریم؛ برای مثال: اگر تا کنون کلاس یوزپلنگ را ندیده‌ایم می‌توانیم از کلاس پلنگ و ببر نمونه قرض بگیریم و برای آموزش کلاس یوزپلنگ از این نمونه‌ها استفاده کنیم. این نمونه‌ها به طور کامل مانند نمونه اصلی نیستند اما به دلیل شباهت‌هایی که دارند می‌توانند برای استفاده مناسب باشند.

به دلیل گستردگی نمونه‌های قرض داده شده می‌توان مدل‌های دسته‌بندی نظارت شده مختلفی را استفاده کرد؛ اما، چون نمونه‌ها همان نمونه‌های کلاس‌های دیده شده هستند باعث می‌شود تا دقت پایینی در دسته‌بندی داشته باشیم.

مبتنی بر سنتز

در این روش برای هر کلاس دیده نشده یک سری نمونه برچسب خورده می‌سازیم و با استفاده از آن‌ها کلاس‌های دیده نشده را آموزش می‌دهیم. در حقیقت پس از ساخت نمونه برای همه کلاس‌ها مسئله به یک مسئله یادگیری ماشین نظارت شده می‌شود. برای تولید داده مصنوعی روش‌های متعددی وجود دارد؛ برای مثال: اگر فرض

کنیم که کلاس‌ها از یک توزیع خاص تبعیت می‌کنند با استفاده از حدس پارامترهای آن توزیع برای کلاس‌های دیده‌نشده می‌توان داده‌های مصنوعی تولید کرد.

از دیگر روش‌ها می‌توان به شبکه‌های GAN اشاره کرد. این شبکه‌ها از دو شبکه ساخته شده‌اند که یکی وظیفه تولید داده و دیگری وظیفه صحت‌سنجی داده را دارد تا داده تولید شده به داده اصلی شبیه‌تر باشد. این شبکه‌ها در تولید داده مصنوعی از روش‌های دیگر از عملکرد و دقت بالاتری برخوردار هستند.

به دلیل گستردگی نمونه‌های تولید شده می‌توان مدل‌های دسته‌بندی نظارت شده مختلفی را استفاده کرد؛ اما، چون نمونه‌های تولید شده به طور معمول از توزیع نرمال پیروی می‌کنند. می‌تواند باعث سوگیری مدل تولید شده شود.

در خارج از شرایط آزمایشگاهی کلاس‌های دیده‌شده و دیده‌نشده در ترکیب با هم هستند و به این سادگی نمی‌توان آن‌ها را جدا از هم در نظر گرفت به همین دلیل می‌باید یادگیری بدون نمونه تعمیم یافته^۱ مطرح می‌شود. در حل این نوع مسائل روش‌های یاد شده لزوماً نتیجه مناسبی نمی‌دهند و باید به دنبال روش‌های بهتر بود.

۳-۳ یک مثال

روش‌ها و فضاها یادگیری در یادگیری بدون نمونه در این فصل بررسی شد در ادامه یک مثال از یادگیری بدون نمونه برای دسته‌بندی حیوانات را برای فهم بهتر بررسی می‌کنیم.

مدل‌های مختلف که بر پایه روش یادگیری بدون نمونه ارائه شده‌اند می‌توانند ترکیبی از روش‌ها و فضاها را داشته باشند و یا فقط متکی بر یکی از آن‌ها طراحی شده باشند. به عنوان مثال در مقاله [۲] از فضای مشخصه استفاده کرده‌است و سعی کرده با ارائه دو روش برای یادگیری حیوانات مختلف را دسته‌بندی کند. مقاله از سه روش برای دسته‌بندی نام برده‌است و آن‌ها را با یکدیگر مقایسه می‌کند. دسته‌بندی چندکلاسه مسطح^۲،

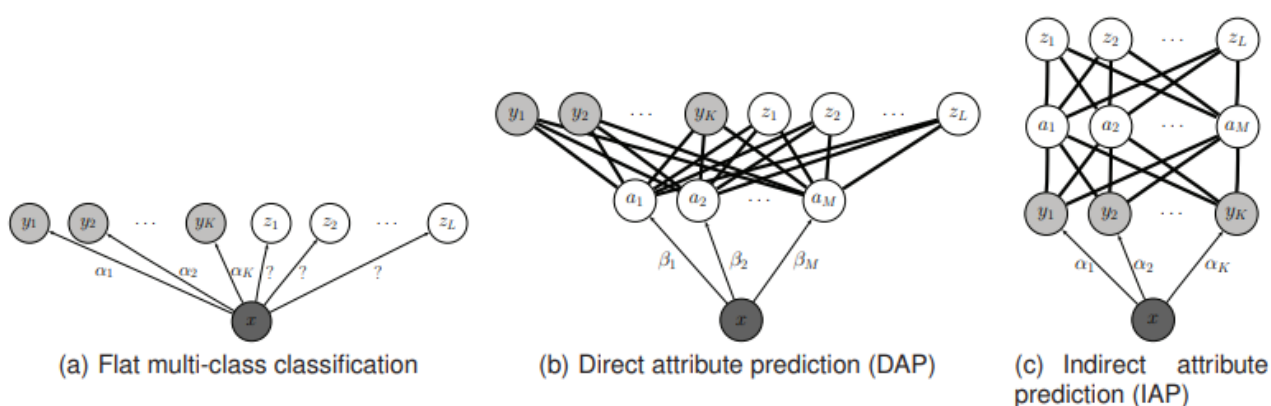
¹Generalized zero-shot learning

²flat multi-class classification

پیش بینی مشخصه به طور مستقیم^۱ و پیش بینی مشخصه به طور غیر مستقیم^۲ به طور شهودی این سه روش در شکل ۳-۲ نشان داده شده‌اند. به دلیل این که همواره نمی‌توان پایگاه داده‌ای کامل و برجسب خورده داشت نیازمند راهکارهایی هستیم تا تلاش انسان در جمع‌آوری و دسته‌بندی داده‌ها را کم کنیم.

در شکل ۳-۲ تصویر الف، نشان دهنده روش اول است. در این روش ماشین یک بردار ثابت را یاد می‌گیرد. x ورودی مسئله، y برجسب داده‌ها آزمایش و z برجسب داده‌هایی است که نیاز داریم آن‌ها را بیابیم. چون فرآیند یادگیری y هیچ تاثیری بر فرآیند یادگیری z ندارد پس از یادگیری‌های قبلی برای پیش بینی نمی‌توان استفاده کرد و این روش یک روش یادگیری معمولی است که قبلاً نیز استفاده می‌شد و برای یادگیری z نیازمند داده‌های ورودی هستیم که با توجه به اینکه به دنبال یادگیری بدون نمونه هستیم این روش مناسب نیست.

راهکار ارائه شده برای یادگیری استفاده از ویژگی‌های معنایی سطح بالایی هستند که هرکدام برای انسان معنای خاصی دارند. این مشخصه‌ها، ویژگی‌های قابل نام‌گذاری هستند؛ مانند: رنگ، شکل، طرح بدن و عادات غذایی. استفاده از این مشخصه‌ها به ما کمک می‌کند تا نقش انسان را در فرآیند یادگیری کمتر کنیم و نیاز کمتری به ویژگی‌های سطح پایین تصویر داشته باشیم.



شکل ۳-۲: روش‌های دسته‌بندی [۲]

¹direct attribute prediction

²indirect attribute prediction

این مشخصه‌ها را می‌توان همراه با تصاویر یا همراه با دسته‌بندی‌های تصاویر در نظر گرفت و این ویژگی باعث شده است تا فرآیند دسته‌بندی بر اساس مشخصه‌ها^۱ توسط مقاله معرفی شود. در این فرآیند با توجه به اینکه دسته‌های آموزش و آزمایش جدا از هم هستند و به یکدیگر وابسته نیستند؛ می‌توان با استفاده از این صفات و انتقال یادگیری^۲، بین داده‌های آموزشی، داده‌های آزمایشی را دسته‌بندی کرد. در شکل ۳؟ می‌توانید نحوه دسته‌بندی بر اساس صفات را مشاهده کنید. با توجه به توضیحات ارائه شده به سراغ توضیح دو روش دیگر می‌رویم.

۳-۳-۱ روش مستقیم

در روش پیش‌بینی مشخصه به صورت مستقیم^۳ یا DAP در مرحله آموزش کلاس خروجی هر نمونه (x) برای لایه مشخصه‌ها نیز به طور قطع یک برجسب (y) مشخص می‌کند. متعاقباً می‌توان از هر روش با نظارتی استفاده کرد و پارامترهای هر مشخصه β_m را پیدا کرد. این بدین معنی است که فرآیند یادگیری اولیه برای یادگیری مشخصه‌ها متناسب با هر نمونه و دسته‌بندی مشخصه‌ها و نمونه‌ها را می‌توان با یک روش یادگیری نظارتی ساده انجام داد. حال با استفاده از یادگیری انتقالی و استفاده از شبکه‌ای که از پیش نمونه‌ها و مشخصه‌ها آن دسته‌بندی شده‌اند برای نمونه‌های جدید که از پیش دیده نشده‌اند (داده‌های آزمون) دسته‌بندی جدیدی را فقط بر اساس لایه مشخصه‌ها وزن‌ها یا پارامترهایی که شبکه تا به حال دارد و به لایه مشخصه‌ها اختصاص داده‌است، استفاده کرد و داده جدید را دسته‌بندی کرد.

۳-۳-۲ روش غیر مستقیم

در روش پیش‌بینی مشخصه به صورت غیر مستقیم^۴ یا IAP همانند روش قبل از مشخصه‌ها برای انتقال دانش بین دسته‌ها استفاده می‌کند اما اینبار مشخصه‌ها بین دو لایه از برجسب‌ها قرار دارند. یک لایه برجسب‌هایی که در لایه آموزش اختصاص می‌یابند (y) و یک لایه برجسب‌هایی که باید به داده‌های جدید اختصاص پیدا کنند (z)

^۱ attribute-based classification

^۲ transfer learning

^۳ direct attribute prediction

^۴ indirect attribute prediction

. در مرحله آموزش پارامترهای لایه مشخصه‌ها توسط برچسب‌های آموزش مقدار دهی می‌شوند همانند یک مسئله دسته‌بندی چندکلاسه که می‌توان با یک روش نظارتی ساده نیز یادگیری را انجام داد. در مرحله آزمایش با استفاده از مقادیری که به لایه مشخصه‌ها اختصاص داده شده دسته‌بندی داده‌های آزمایش را صورت می‌گیرد. استفاده از لایه مشخصه‌ها به برای دسته‌بندی داده‌های آزمایش این امکان را می‌دهد تا بتوانیم عملیاتی مشابه تنظیم^۱ را انجام دهیم و فقط ترکیبات با معنی از مشخصه‌ها را ایجاد کنیم.

روش‌های یاد شده یک سری استراتژی کلی محسوب می‌شوند که می‌توانند با ترکیبی از روش‌های موجود مانند: یادگیری با نظارت یا رگرسیون‌ها بر روی مشخصه‌ها تصاویر یا دسته‌های تصاویر با استفاده از پارامترهای پیش‌بینی شده انجام شوند. در این مقاله از روش توزیع‌های احتمالاتی استفاده شده و مشخصه‌های استفاده شده را مشخصه‌هایی بله یا خیر در نظر گرفته‌است. برای مشخصه‌هایی که بله یا خیر نیستند می‌توان به جای دسته‌بندی از رگرسیون استفاده کرد.

در روش DAP برای دسته‌بندی کردن تصاویر آزمون، احتمال قطعی به دست خواهد آمد زیرا در مرحله آموزش لایه مشخصه‌ها مقادیر مناسب را اتخاذ می‌کنند و از همین مقادیر برای تصاویر آزمون نیز استفاده می‌شود. به زبان ریاضی معادلات زیر صادق است.

$$p(z|x) = \sum_{a \in (0,1)^M} p(z|a)p(a|x) \frac{p(z)}{p(a)} \prod_{m=1}^M p(a_m^z|x). \quad (۱-۳)$$

$$f(x) = \operatorname{argmax}_{l=1,\dots,L} p(z=l|x) = \operatorname{argmax}_{l=1,\dots,L} \prod_{m=1}^M \frac{p(a_m^{z_l}|x)}{p(a_m^{z_l})}. \quad (۲-۳)$$

در روش IAP لایه مشخصه‌ها نقش یک تنظیم‌کننده را ایفا می‌کند پس به طور قطع نمی‌توان برای تشخیص

^۱regularization

لایه آزمون استفاده کرد و می‌بایست با استفاده از روابط احتمال یک احتمال میانی را حساب کرد و پس از آن از رابطه ۳-۲ استفاده کرد.

$$p(a_m|x) = \sum_{k=1}^K p(a_m|y_k)p(y_k|x). \quad (3-3)$$

۳-۳-۳ بانک‌های اطلاعاتی

سه بانک اطلاعاتی استفاده شده است. در ادامه هر یک را توضیح می‌دهیم. ۳-۱

Animal with Attributes

این بانک اطلاعاتی به عنوان بانک اصلی استفاده شده است. این بانک شامل ۵۰ کلاس حیوانات و ۸۵ کلاس مشخصه‌های معنایی است؛ از این تعداد ۴۰ کلاس به عنوان داده‌های آموزشی و ۱۰ کلاس به عنوان داده‌های آزمایش استفاده شده است. تقسیم بندی به صورت تصادفی نیست اما سعی شده است تا توزیع داده‌ها در هر دو دسته آزمایش و آزمون به طور مناسبی صورت شود.

در کل ۳۰۴۷۵ عکس در این بانک داده وجود دارد که تعداد تصاویر برای دسته‌های مختلف حیوانات متفاوت می‌باشد. برای تسریع در محاسبات یک سری از ویژگی‌های تصاویر مانند: جنبه‌های رنگ، بافت و شکل، هیستوگرام رنگ و سایر ویژگی‌های مهم تصویر نیز به پایگاه داده اضافه شده و برای آموزش از روش 5 fold cross-validation استفاده شده است.

aPascal-aYahoo

این بانک شامل دو دسته داده یکی داده‌های بانک داده PASCAL و دیگری داده‌هایی که از موتور جستجوی Yahoo استخراج شده است. ۲۰ کلاس داده در PASCAL و ۱۲ کلاس داده در Yahoo و دسته‌بندی داده‌ها در هر یک با دیگری متفاوت است پس می‌توان از داده‌های PASCAL برای آموزش و از داده‌های Yahoo برای آزمون استفاده کرد. هر تصویر ۶۴ مشخصه‌ها دودویی را شامل می‌شود و همانند بانک داده قبلی برای تسریع در

محاسبات یک سری از ویژگی‌های تصاویر از قبل محاسبه شده‌اند.

SUN Attributes

این بانک زیر مجموعه‌ای از بانک داده SUN Database که شامل ۷۱۷ کلاس داده و هر تصویر شامل ۱۰۲ مشخصه دودویی است. این مشخصه‌ها شامل توضیفات صحنه، شرایط نورپردازی، مواد داخل تصویر و ... است.

جدول ۳-۱: بانک‌های اطلاعاتی [۲]

SUN	aP/aY	AwA	Dataset
۱۴۳۴۰	۱۵۳۳۹	۳۰۴۷۵	# Images
۷۱۷	۳۲	۵۰	# Classes
۱۰۲	۶۴	۸۵	# Attributes
image per binary	image per binary	class per both	Annotation Level (real- Type Annotation binary) or valued

۴-۳-۳ ارزیابی

برای این کار از ماشین بردار پشتیبان^۱ یا SVM استفاده شده‌است. برای روش مستقیم از یک SVM غیر خطی و برای روش غیرمستقیم از نوع one-versus-rest استفاده شده‌است. نتایج به دست آمده را در جداول ۳-۳-۲ و ۳-۳-۳ مشاهده می‌کنید.

جدول ۳-۲: تقسیم بندی پیش فرض داده‌ها [۲]

rnd	CT-H	CT-cc	IAP	DAP	method
۰.۱۰	30.8 ± 0.2	30.7 ± 0.2	۲.۴۲	۴.۴۱	MC acc.
۰.۵۰	۴.۷۳	۴.۷۳	۰.۸۰	۴.۸۱	classAUC
۰.۵۰	—	—	۱.۷۲	۸.۷۲	attrAUC

جدول ۳-۳: تقسیم بندی داده‌ها به صورت تصادفی [۲]

md	CT-H	CT-cc	LAP	DAP	method
۰.۱۰	27.3 ± 4.0	27.7 ± 4.3	34.1 ± 5.1	37.1 ± 3.9	MC acc.
۰.۵۰	72.8 ± 3.1	72.4 ± 2.7	76.3 ± 5.5	80.4 ± 3.1	classAUC
۰.۵۰	—	—	69.7 ± 3.8	70.7 ± 3.5	attrAUC

در روش مستقیم برای بدست آوردن مقادیر مناسب کرنل از SVM منحنی ROC^۲ و میانگین سطح زیر منحنی^۳

^۱Support Vector Machine


^۲Receiver Operation Characteristic

^۳AUC

برای صفات و روش 5 fold cross-validation استفاده شده است.

منحنی یاد شده، یک نمودار برای نمایش توانایی ارزیابی یک سیستم دسته‌بندی دودویی محسوب می‌شود که آستانه تشخیص آن نیز متغیر است. که با ترسیم نسبت نرخ مثبت صحیح^۱ که به اختصار TPR نامیده می‌شود برحسب نرخ مثبت کاذب^۲ با نام اختصاری FPR ایجاد می‌شود.

در روش غیر مستقیم مراحل مانند روش قبل است با این تفاوت که میانگین سطح زیر منحنی بر روی پیش‌بینی کلاس‌ها استفاده شده است.



شکل ۳-۳: منحنی ROC [۲]

همان‌طور که در شکل ۳-۳ مشاهده می‌کنید. دقت روش در تشخیص برخی از دسته‌ها مانند نهنگ‌های کوهان‌دار دقت بالایی همانند روش‌های یادگیری با نظارت دارد؛ اما در مورد دسته‌بندی‌هایی مانند خوک‌ها و پاندهای بزرگ دقت خیلی پایینی دارد. یکی از دلایل این اتفاق شباهت‌هایی است که در این دسته‌ها رخ می‌دهد؛ به طور مثال: ظاهر پاندهای بزرگ، خوک‌ها و اسب‌های آبی.

به طور مشابه بر روی دو پایگاه داده دیگر نیز بررسی‌ها انجام شده است و نتایج را در جداول ؟؟ ؟؟ مشاهده می‌کنید.

¹True Positive Rate

²False Positive Rate

جدول ۳-۴: تقسیم بندی پیش فرض داده ها برای aPascal-aYahoo [۲]

rnd	CT-H	IAP	DAP-C	DAP-I	method
۳.۸	16.7 ± 0.5	۹.۱۶	۱.۱۹	۸.۱۶	MC acc.
۰.۵۰	۲.۶۴	۴.۷۵	۵.۷۶	۹.۷۶	classAUC
۰.۵۰	—	۱.۷۳	۷.۷۳	۶.۷۰	attrAUC

جدول ۳-۵: تقسیم بندی داده ها برای attributes sub [۲]

rnd	CT-H	IAP	DAP-C	DAP-I	method
۴.۱	12.9 ± 1.3	18.0 ± 1.5	22.2 ± 1.6	18.1 ± 1.2	MC acc.
۲.۶	32.6 ± 2.0	41.1 ± 2.1	46.6 ± 1.7	40.2 ± 2.1	level2 acc.
۳.۳۳	74.2 ± 2.0	82.1 ± 2.5	85.7 ± 2.1	74.2 ± 4.0	level1 acc.
۰.۵۰	77.1 ± 0.0	87.9 ± 0.7	92.3 ± 0.7	90.5 ± 0.7	class mAUC
۰.۵۰	—	82.7 ± 0.8	83.9 ± 0.8	82.0 ± 0.6	attrAUC

۵-۳-۳ نتیجه

با بررسی این مثال و بررسی های کلی ارائه شده در مورد یادگیری بدون نمونه سعی کردیم تا به طور کلی این مبحث را پوشش دهیم. کاربرد روش بدون یادگیری بسیار گسترده است و می تواند جایگزین بسیاری از روش های سنتی شود. از کاربردهای آن می توان به استفاده در تشخیص حرکت در ویدیو و جلوگیری از جعل هویت اشاره کرد که کارهای بسیاری در این زمینه ها انجام شده است.

فصل چهارم

روش پیشنهادی

فصل پنجم

پیاده‌سازی

فصل ششم

ارزیابی کارایی

فصل هفتم

جمع بندی و نتیجه گیری

References

- [1] G. Koch, R. Zemel, and R. Salakhutdinov, “Siamese Neural Networks for One-shot Image Recognition,” tech. rep., 2015.
- [2] C. H. Lampert, H. Nickisch, and S. Harmeling, “Attribute-based classification for zero-shot visual object categorization,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 36, pp. 453–465, mar 2014.
- [3] W. Wang, V. W. Zheng, H. Yu, and C. Miao, “A Survey of Zero-Shot Learning,” *ACM Transactions on Intelligent Systems and Technology*, vol. 10, pp. 1–37, jan 2019.