

بسم الله الرحمن الرحيم



دانشگاه شهید بهشتی

پژوهشکده فضای مجازی

ارائه روشی برای تشخیص جعل تصویر چهره بر پایه یادگیری بدون نمونه

پایان نامه کارشناسی ارشد فناوری اطلاعات گرایش چند رسانه‌ای

سید مصطفی حسینی کشکوئیه

استاد راهنما

دکتر احمد محمودی ازناوه



دانشگاه شهید بهشتی
پژوهشکده فضای مجازی

پایان نامه کارشناسی ارشد – آقای سید مصطفی حسینی کشکوئی
تحت عنوان
ارائه روشی برای تشخیص جعل تصویر چهره بر پایه یادگیری بدون نمونه

در تاریخ توسط کمیته‌ی تخصصی زیر مورد بررسی و تصویب نهایی قرار گرفت:

۱ - استاد راهنمای پایان نامه دکتر

۳ - استاد داور دکتر

۴ - استاد داور دکتر

سرپرست تحصیلات تکمیلی دانشکده دکتر

تشکر و قدردانی

پروردگار منان را سپاسگزارم.

کلیه حقوق مالکیت مادی و معنوی مربوط
به این پایان نامه متعلق به دانشگاه شهید
بهشتی و پدیدآورندگان است. این حقوق
توسط دانشگاه شهید بهشتی و بر اساس
خط مشی مالکیت فکری این دانشگاه،
ارزش گذاری و سهم بندی خواهد شد. هر
گونه بهره برداری از محتوا، نتایج یا اقدام
برای تجاری سازی دستاوردهای این پایان
نامه تنها با مجوز کتبی دانشگاه شهید بهشتی
امکان پذیر است.

فهرست مطالب

عنوان

صفحه

فهرست مطالب	هفت
فهرست تصاویر	نه
فهرست جداول	ده
چکیده	۱

فصل اول: مقدمه

۲	
۱-۱	صورت مسئله
۲-۱	اهداف پژوهش
۳-۱	نواوری پژوهش
۴-۱	ساختار پایان نامه

فصل دوم: پیش زمینه

۵	
۱-۲	یادگیری با یک نمونه
۲-۲	یادگیری بدون نمونه
۱-۲-۲	فضاهای مهندسی شده
۲-۲-۲	فضاهای یادگرفته شده
۳-۲-۲	روش های بر پایه دسته بند
۴-۲-۲	روش های بر پایه نمونه
۵-۲-۲	یک مثال
۳-۲	شبکه های GAN و روش های حمله
۴-۲	جمع بندی

فصل سوم: کارهای مرتبط

۲۴

فصل چهارم: روش پیشنهادی

۲۵

فصل پنجم: پیاده سازی

۲۶

فصل ششم: ارزیابی کارایی

۲۷

فصل هفتم : جمع بندی و نتیجه گیری

۲۸

۲۹ مراجع

فهرست تصاویر

۶	۱-۲ شبکه ساده سیامی برای دسته بند دودویی [۱]
۹	۲-۲ نحوه دسته بندی تصاویر توسط مدل ارائه شده [۲]
۱۷	۳-۲ روش های دسته بندی [۲]
۲۲	۴-۲ منحنی [۲ROC]

فهرست جداول

۲۰	۱-۲ بانک‌های اطلاعاتی[۲]
۲۱	۲-۲ تقسیم بندی پیش فرض داده‌ها [۲]
۲۱	۳-۲ تقسیم بندی داده‌ها به صورت تصادفی[۲]
۲۲	۴-۲ تقسیم بندی پیش فرض داده‌ها برای [۲aPascal-aYahoo]
۲۲	۵-۲ تقسیم بندی داده‌ها برای [۲attributes] sub

چکیده

جمع آوری داده و پرچسب زدن داده‌ها از مهم‌ترین مراحل پیش‌پردازش در یادگیری ماشین است. اما همواره جمع‌آوری به سادگی نیست و ما به داده‌های برچسب‌خورده دسترسی نداریم. عدم دسترسی به دادگان مناسب، هزینه زیاد جمع آوری دادگان و مشاهده نمونه‌های جدید از عوامل حرکت به سمت یادگیری با نمونه کم، یک نمونه و در نهایت بدون نمونه بوده‌اند.

در سیستم‌های تشخیص چهره، یکی از ارکان اساسی برای سلامت و کارایی سیستم توانایی جلوگیری از حملات مختلف و تشخیص جعل تصویر است. راهکارها و روش‌های بسیاری در طول سالیان مخلف ارائه شده است؛ اما نکته حائز اهمیت تغییر کردن و به‌روز شدن حملات است که باعث می‌شود این کشمکش بین حملات و سیستم‌های تشخیص حملات و جعل تصاویر همواره وجود داشته باشد.

از روش‌های پر کاربردی که برای تولید تصاویر جعلی و انجام حملات به سیستم‌های تشخیص چهره استفاده می‌شود روش‌های تخاصمی و استفاده از شبکه‌های متولد متخاصم است. جلوگیری از این حملات و نیازمند روش‌های هوشمند و به‌روزی است به همین به سراغ استفاده از روش یادگیری بدون نمونه رفته‌ایم تا بتوانیم با استفاده از آن از حملات جلوگیری کنیم و جعل تصویر چهره را تشخیص دهیم.

واژه‌های کلیدی: ۱- یادگیری ماشین ۲- جعل تصویر چهره ۳- شبکه‌های مولد تخاصمی ۴- یادگیری بدون نمونه

فصل اول

مقدمه

تشخیص چهره یکی از روش‌های احراز هویت بیومتریک^۱ است که در قدیم توسط سیستم‌های امنیتی پیشرفته انجام می‌شد. در روش‌های بیومتریک از اثر انگشت یا کل دست، عنبیه چشم، صدا، چهره و غیره استفاده می‌شود که متداول‌ترین آن استفاده از چهره فرد است. امروزه با توجه به پیشرفت تکنولوژی و همه‌گیر شدن آن تشخیص چهره را در گوشی‌های هوشمند همراه می‌توان یافت.

همه‌گیری این تکنولوژی باعث پیشرفت‌های فراوان آن نیز شده است و امروزه گوشی‌های همراه می‌توانند به سرعت و با دقت بالا تشخیص چهره را انجام دهند و تقریباً به بهترین شکل اینکار را انجام می‌دهند. اما به امنیت این سیستم‌ها به اندازه کافی توجه نشده است. به این سیستم‌ها حملات متعددی صورت می‌گیرد که می‌توانند باعث خرابی سیستم، جعل هویت و یا گرفتن دسترسی کامل توسط حمله‌کننده و هکرها شود. این سیستم‌ها به طور عمده

^۱biometric authentication

امروزه بر اساس شبکه‌های عصبی عمیق یا DNN^۱ و شبکه‌های عصبی کانولوشن یا CNN^۲ ساخته می‌شوند. در مقالات زیادی انواع حملات به این نوع شبکه‌ها بررسی شده‌اند.

تشخیص حملات و مقابله با آن‌ها یکی از مواردی است که باید به آن توجه ویژه‌ای داشت. یکی از مشکلات اساسی در حملات و جعل تصاویر صورت گرفته دسته‌بندی حملات و تشخیص نوع حمله است که به آسانی توسط انسان امکان‌پذیر نیست.

۱-۱ صورت مسئله

تشخیص و دسته‌بندی حملات به سیستم‌های تشخیص چهره و جعل تصاویر چهره از بزرگ‌ترین معزلات توسعه دهندگان این سیستم‌هاست. تضمین امنیت سیستم برای جلوگیری از دور زدن سیستم، گرفتن دسترسی‌های بیشتر و یا احراز هویت به جای فرد دیگری توسط هکرها از مواردی است که توسعه دهندگان باید مد نظر داشته باشند. با توجه به اینکه به طور عمده حملات در دسته‌های مشخصی قرار می‌گیرند و ویژگی‌هایی دارند که می‌توان آن‌ها را دسته‌بندی کرد استفاده از روش‌های دسته‌بندی به شیوه‌های مختلف می‌تواند کارآمد و کمک‌کننده باشد.

برای دسته‌بندی باید بتوانیم ویژگی‌های حملات مختلف را تشخیص دهیم. تشخیص این ویژگی‌ها به سادگی تشخیص ویژگی‌های تصاویر حیوانات مختلف برای دسته‌بندی آن‌ها نیست و ویژگی‌ها پیچیده‌تر و نیازمند سیستم‌های تشخیص دقیق‌تری هستند. بعد از تشخیص ویژگی‌های مورد نظر می‌توان حمله را دسته‌بندی کرد و متناسب با نوع حمله با آن مقابله کرد.

۱-۲ اهداف پژوهش

تجربه نشان داده است که یادگیری بدون نمونه برای دسته‌بندی و تشخیص نمونه‌هایی که کمتر تا کنون دیده شده‌اند یا اصلاً دیده نشده‌اند، موفق عمل کرده و توانسته دسته‌بندی را به نحو احسن انجام دهد. استفاده از

^۱Deep Neural Networks

^۲Convolutional Neural Network

یادگیری بدون نمونه در مواردی که پیدا کردن ویژگی‌های مشترک مانند حیوانات و اشیاء پیرامون به سادگی نیست و نمی‌توان فهرستی از ویژگی‌های مشترک را به آسانی تهیه کرد؛ موفق عمل کرده است. هدف پژوهش استفاده از دادگان‌های موجود و پر کاربرد در حوزه جعل تصویر چهره و یادگیری بدون نمونه برای ارائه راهکاری که قابلیت تشخیص و دسته‌بندی حملات مختلف به سیستم‌های تشخیص چهره را با دقتی نزدیک به دقت تشخیص چهره دارد، است.

۱-۳ نوآوری پژوهش

۱-۴ ساختار پایان‌نامه

در فصل دوم، به بررسی اجمالی درباره یادگیری بدون نمونه و انواع آن می‌پردازیم و همچنین حملات و جعل‌های مختلف تصویر چهره را بررسی می‌کنیم. در فصل سوم، کارهای مرتبط به این پژوهش بررسی می‌شوند و مزایا و معایب آن‌ها به طور مختصر بررسی می‌گردد. در فصل چهارم، به تفصیل روش پیشنهادی و ایده اصلی بیان شده است. نحوه پیاده‌سازی و ساختار مدل بررسی شده است. در فصل ششم نتایج و ارزیابی‌های مرتبط بررسی شده و میزان کارایی و نتایج به دست آمده مورد تحلیل قرار گرفته است و در نهایت در فصل هفتم جمع‌بندی پایانی صورت گرفته است.

فصل دوم

پیش زمینه

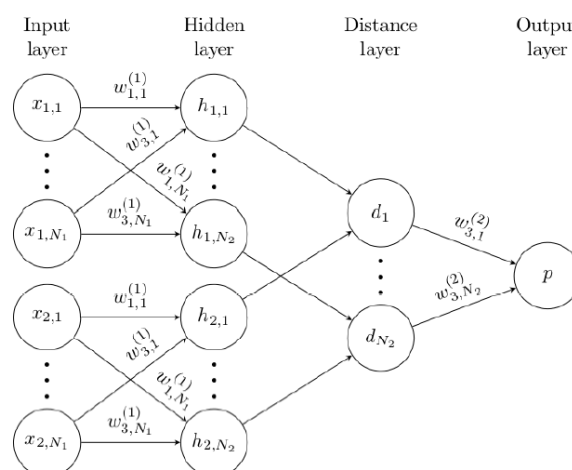
۱-۲ یادگیری با یک نمونه

در یادگیری به صورت سنتی، باید داده‌ها با دو دسته آموزش و آزمون تقسیم‌بندی شوند و برای هر کلاس جدید برای دسته‌بندی باید به تعداد کافی داده وجود داشته باشد تا مدل بتواند دسته‌بندی مناسبی انجام دهد. مانند مدل کانولوشن ساده‌ای که با آن می‌توان سگ و گربه را از هم تفکیک داد. این مدل برای هر داده سگ و گربه باید تعداد قابل توجهی داده دیده باشد تا بتواند دسته‌بندی را به درستی انجام دهد. حال برای دسته‌بندی یک حیوان دیگر توسط این مدل باید داده‌های جدیدی به مدل بدهیم تا مدل بتواند آن نوع حیوان را نیز دسته‌بندی کند.

با بهبود ساختار شبکه یادگیرنده می‌توان نیاز فرآیند یادگیری به داده‌های زیاد را کاهش داد تا مدل بتواند با داده‌های کم نیز دسته‌بندی را انجام دهد. ارائه راهکارها و روش‌هایی در کنار استفاده از شبکه‌های عصبی این امکان را به وجود آورد تا مدل فقط با دیدن یک نمونه از یک کلاس داده در فرآیند آموزش بتواند داده جدید را

دسته‌بندی کند. این روش با نام یادگیری با یک نمونه شناخته می‌شود.

در این روش در فرآیند آموزش مدل به حداقل یک داده از یک کلاس داده نیاز دارد. برای جلوگیری از بیش‌برازش^۱ در فرآیند آموزش از روش‌هایی مانند ایجاد اعوجاج در داده‌ها برای تولید داده جدید در حالات مختلف استفاده می‌شود تا مدل بتواند دسته‌بندی بهتری انجام دهد. فرآیند یادگیری با یک نمونه در مواردی پر کاربردتر است که ما تمامی کلاس‌های داده را از قبل داشته باشیم؛ برای مثال: در مبحث پردازش زبان طبیعی انسان، ساختار هر زبان مشخص است و زبان‌ها از یکدیگر با ساختارهای مشخص قابل تفکیک هستند و هر زبان تعداد ثابتی قواعد و واژگان دارد. این قابلیت به ما کمک می‌کند تا بتوانیم از مدل یادگیری با یک نمونه برای کاربرد پردازش زبان طبیعی استفاده کنیم.



شکل ۲-۱: شبکه ساده سیامی برای دسته بند دودویی [۱]

شبکه سیامی^۲ برای تشخیص زبان سیامی یکی از زبان‌های آسیایی است و ساختار مشخص و واژگان ثابتی را دارد ایجاد شد. این شبکه به صورت یک شبکه عصبی دو قلو است. برای دسته‌بندی این شبکه دوتایی‌های مشابه و مخالف را ایجاد می‌کند. یعنی با استفاده از شباهت‌ها و تفاوت‌های موجود درون کاراکترهای زبان آن‌ها را دسته‌بندی می‌کند در انتها هنگام دریافت نمونه جدید شبکه شباهت و تفاوت‌های این نمونه با نمونه‌های موجود

¹over fitting

²Siamese network

را تشخیص می‌دهد و آن را در یک دسته قرار می‌دهد.

برای محاسبه تفاوت و شباهت یک معیار فاصله وزن دار L_1 بین بردارهای ویژگی استخراج شده از دو شبکه دو قلو استفاده کرده و بر اساس آن نرخ یادگیری شبکه و نحوه دسته‌بندی واژگان را مشخص کرده‌است. در شکل ۲-۱ یک نمونه ساده از این شبکه برای دسته‌بندی دودویی را مشاهده می‌کنید.

شبکه سیامی یکی از شبکه‌های پر کاربرد در یادگیری عمیق است که در سیستم‌های تشخیص چهره نیز کاربرد دارد. در ادامه بررسی حملات یک مدل حمله به این شبکه نیز بررسی خواهد شد. به دلیل اینکه پایه کار و روش پیشنهادی یادگیری بدون نمونه است، در این بخش به طور مفصل آن را همراه با چند مثال بررسی می‌کنیم.

۲-۲ یادگیری بدون نمونه

در یادگیری بدون نمونه ما با دو نوع داده سروکار داریم. داده‌های دیده‌شده که برای آموزش مدل از آن‌ها استفاده می‌کنیم و داده‌های دیده‌نشده که مدل آموزش دیده باید بتواند آن‌ها را دسته‌بندی کند. داده‌های دیده‌شده، داده‌هایی برچسب خورده هستند و یک سری ویژگی‌های مشخص دارند. مدل آموزش دیده بر اساس این داده‌ها باید بتواند داده‌های دیده‌نشده را بر اساس ویژگی‌های استخراج کرده و ویژگی‌های داده‌های قبل، داده‌های جدید را دسته‌بندی کند.

فرآیند یادگیری و بررسی مدل، دو فرآیند جدا از هم هستند و داده‌های دیده‌شده و دیده‌نشده با یکدیگر اشتراکی ندارند. (به این مدل، مدل مجموعه باز^۱ گفته می‌شود.) بر این اساس می‌توان از روش یادگیری انتقالی برای یادگیری مدل‌های بر پایه یادگیری بدون نمونه استفاده کرد. در یادگیری انتقالی مدل یکبار با استفاده از داده‌های مناسب وزن‌دهی و مقداردهی شده است، حال کافی است مدل آماده را برای تشخیص داده‌های جدید یا در روش‌های دیگر برای فعالیت‌های دیگر به کار گرفت و نیاز نیست تا دوباره از ابتدا فرآیند یادگیری را از سر بگیریم. فرآیند یادگیری انتقالی مانند نوزاد انسان است که در ابتدا درباره محیط اطراف اطلاعات کمی دارد اما

^۱open-set

کم کم از محیط یاد می‌گیرد و از تجربیات قبلی در یادگیری‌های بعدی نیز استفاده می‌کند.

چند حالت کلی رایج وجود دارد که استفاده از یادگیری بدون نمونه در این موارد به ما کمک می‌کند:

- وقتی فضای هدف به قدری بزرگ هست که همواره نمی‌توان تمامی حالات ممکن را پوشش داد؛ برای مثال:

در تشخیص اشیا اطراف همواره اشیا جدید وجود دارد که در یک دسته‌بندی جدا قرار می‌گیرد.

- ممکن است نمونه‌های کلاس هدف کم‌یاب باشند و به سادگی به آن‌ها دسترسی نداشته باشیم؛ برای مثال: در

تشخیص گونه‌های مختلف یک گیاه ممکن است همواره گونه‌های جدیدی پیدا شوند که تا به حال دیده

نشده‌اند و یا گونه‌هایی باشند که دسترسی به آن‌ها دشوار است.

- ممکن است نمونه‌های کلاس هدف در طول زمان دچار تغییر شوند؛ مانند: نمونه‌های برندهای مختلف

پوشاک

- ممکن است داده وجود داشته‌باشد اما فرآیند برچسب‌گذاری هزینه‌بر باشد.

با توجه به اینکه داده‌های کلاس هدف را تا کنون ندیده‌ایم، نیاز به یک سری اطلاعات جانبی^۱ داریم تا بتوانیم

ارتباطی بین داده‌های آموزش و داده‌های هدف پیدا کنیم. اطلاعات جانبی باید در فضای ویژگی مرتبط با نمونه‌ها

باشند تا بتوانیم به عنوان اطلاعات مناسب از آن‌ها استفاده کنیم؛ به طور مثال: در مسئله تشخیص حیوانات در

صورتی که مدل ما اسب و ببر را دیده باشد می‌تواند آن‌ها را دسته‌بندی کند. حال اگر یک نمونه تصویر گورخر

به مدل نشان دهیم با توجه به اینکه تاکنون مدل آن را ندیده‌است باید بتوانیم با روشی به مدل بفهمانیم تا بتواند

آن را نیز دسته‌بندی کند. گورخر جثه‌ای شبیه به اسب و طرحی شبیه به ببر دارد؛ این‌ها اطلاعات جانبی است که

با استفاده از آن‌ها می‌توانیم بین داده‌های کلاس آموزش و هدف ارتباط برقرار کنیم. نمونه استفاده از اطلاعات

جانبی در دسته‌بندی را می‌توانید در شکل ۲-۲ مشاهده کنید.

^۱auxiliary information

اطلاعات جانبی مورد استفاده به طور معمول یکسری اطلاعات معنایی هستند. این اطلاعات کمکی در یک فضای جدید (فضای معنایی^۱) شامل هر دو دسته کلاس‌های دیده‌شده و دیده‌نشده می‌شوند. فضای معنایی نیز مانند فضای ویژگی یک فضای چند بعدی است. در فضای معنایی هر کلاس با یک توصیف برداری شناخته می‌شود که به این توصیف برداری، ضابطه کلاس^۲ گویند.

otter

black: yes
white: no
brown: yes
stripes: no
water: yes
eats fish: yes

polar bear

black: no
white: yes
brown: no
stripes: no
water: yes
eats fish: yes

zebra

black: yes
white: yes
brown: no
stripes: yes
water: no
eats fish: no

otter

black: yes
white: no
brown: yes
stripes: no
water: yes
eats fish: yes

polar bear

black: no
white: yes
brown: no
stripes: no
water: yes
eats fish: yes

zebra

black: yes
white: yes
brown: no
stripes: yes
water: no
eats fish: no



شکل ۲-۲: نحوه دسته بندی تصاویر توسط مدل ارائه شده [۲]

به طور کلی مقالات حوزه یادگیری بدون نمونه به دو طریق بر اساس تفاوت‌های فضای معنایی و بر اساس تفاوت روش‌های استفاده شده بررسی شده‌اند. فضاهای استفاده شده در دو دسته مهندسی شده^۳ و فضاهای یادگرفته شده^۴ و روش‌ها در دو دسته بر پایه دسته‌بند^۵ و بر پایه نمونه^۶ بررسی می‌شوند. [۳]

^۱semantic space

^۲class prototype

^۳Engineered

^۴Learned

^۵classifier-based

^۶instance-base

فضاهای مهندسی شده توسط متخصصان طراحی و متناسب با کاربرد مورد نظر استفاده شده‌اند. نمونه‌های پر کاربرد آن‌ها می‌توان به فضای مشخصه^۱، لغوی^۲ و متنی-کلیدواژه‌ها^۳ اشاره کرد که هر یک را مختصر توضیح می‌دهیم.

فضای مشخصه

بر اساس یک سری مشخصه‌ها ساخته شده‌اند. مشخصه‌ها ویژگی‌های سطح بالایی هستند که برای انسان یک معنا و مفهومی را تداعی می‌کنند؛ مانند: رنگ پوست، نوع زیست و محیط زندگی. این ویژگی‌ها را نمی‌توان همانند ویژگی‌های سطح پایین مانند شکل و فرم کلی بدن با استفاده از شبکه‌های عصبی کانولوشنی یاد گرفت. کاربرد این مشخصه‌ها در انتقال یادگیری است. زیرا ویژگی‌های سطح پایین برای انتقال یادگیری در یادگیری بدون نمونه ارزش چندانی ندارند. این نوع از فضا به چند دسته تقسیم بندی می‌شود: دودویی، پیوسته و نسبی.

در مقاله Lampert^{۲۰۱۴} [۲] برای دسته‌بندی حیوانات یک پایگاه داده با فضای مشخصه پایگاه داده^۴ معرفی شده است. که شامل بیش از ۳۰۰۰۰ تصویر حیوانات در ۵۰ دسته مختلف و ۸۵ ویژگی معنایی است.

فضای لغوی

مجموعه لغاتی هستند که بر پایه برچسب کلاس‌ها و داده‌هایی اند که اطلاعات معنایی دارند. مجموعه لغات استفاده شده می‌تواند WordNet باشد و برای ایجاد رابطه می‌توان روابط خواهر-برادی، والد-فرزندی و یا هر رابطه قابل تعریف دیگری استفاده کرد.

¹ Attribute

² lexical

³ text-keywords

⁴ Animals with Attributes-AwA

این فضا بر اساس کلیدواژه‌ها ساخته شده‌اند. کلید واژه‌ها را می‌توان از هر منبعی یا سایتی مانند ویکی‌پدیا استخراج کرد. این کلیدواژه‌ها از توصیفاتی که درباره کلاس‌های مختلف وجود دارند استخراج می‌شوند.

به طور خلاصه فضاهاى مهندسی شده توسط افراد متخصص طراحی می‌شوند و می‌توانند انعطاف پذیر باشند و متناسب با فضای معنایی و قوانین دلخواه تولید شوند؛ اما نکته منفی در مورد آن‌ها این است که وابسته به یک متخصص هستیم و تلاش انسانی زیادی برای تولید آن‌ها باید صورت گیرد.

۲-۲-۲ فضاهاى یادگرفته شده

این فضاها بر خلاف مدل قبلی توسط ماشین یاد گرفته شده‌اند. در این فضاها هر بعد به تنهایی نمی‌تواند بیانگر یک معنا و مفهوم باشد و ابعاد مختلف در کنار هم معنا پیدا می‌کنند. مدل‌های ماشینی استفاده شده برای یادگیری این فضاها می‌توانند مدل‌های از قبل آموزش دیده باشند یا می‌توان از پایه یک مدل را طراحی کرد. سه فضای پر کاربرد می‌توان به جایگذاری برچسب^۱، جایگذاری متن^۲ و نمایش تصویر^۳ اشاره کرد.

فضای جایگذاری برچسب

این فضا بر اساس روش جایگذاری کلمه در پردازش زبان طبیعی ساخته شده‌است. در این روش، کلمات در فضایی از اعداد حقیقی جایگذاری می‌شوند و در نتیجه یک بردار در فضای جایگذاری به ازای هر کلمه ایجاد خواهد شد. این فضا حاوی اطلاعات معنایی است و کلماتی که حاوی معنایی نزدیک و مشابه اند در نزدیکی یکدیگر قرار می‌گیرند. در یادگیری بدون نمونه برچسب هر کلاس یک کلمه است که می‌توان از این روش استفاده کرد.

¹ Label-embedding

² Text-embedding

³ Image-representation

این فضا شبیه به فضای متن - کلیدواژه در فضاهای مهندسی شده است با این تفاوت که در این فضا ماشین ارتباطات و ضوابط بین کلاس ها و متون را پیدا خواهد کرد.

فضای نمایش تصویر

در این فضا برای هر کلاس تعدادی تصویر به عنوان نمونه انتخاب خواهد شد. این نمونه ها به یک ماشین، داده خواهد شد تا ارتباط بین تصاویر و کلاس های مورد نظر را پیدا کند و از آن طریق بردارهای خروجی را یافته و ضابطه کلاس ها را تشکیل دهد. برای مقابله با حملات و جعل تصاویر چهره ما نیاز به تولید چنین فضاهایی هستیم.

به طور خلاصه فضاهای یادگرفته شده نیازی به یک انسان متخصص ندارند و می توانند ویژگی هایی را تولید کنند که شاید از دید متخصص پنهان بنمان که این می تواند یک برتری نسبت به فضای مهندسی شده باشد. از طرفی، این نکته که هر بعد این فضاها به تنهایی یک معنا و مفهوم مستقل ندارد می تواند یک نقطه ضعف در مقابل فضاهای مهندسی شده باشد.

۲-۲-۳ روش های بر پایه دسته بند

هدف و تمرکز در این روش ها این است که از یک دسته بند برای تشخیص کلاس های دیده نشده استفاده کنیم. روش این دسته بندها یک در مقابل بقیه^۱، است که در این روش در هر تصمیم گیری برای کلاس دیده نشده یک مسئله دسته بندی دودویی وجود خواهد داشت. در حقیقت این روش ها یک سری دسته بند دودویی در کنار هم هستند. روش های ساخت دسته بندها در ادامه آورده شده است. این روش ها در سه دسته مبتنی بر تطابق^۲، مبتنی بر ارتباط^۳ و مبتنی بر ترکیب^۴ بررسی می شوند.

¹ one versus rest

² Correspondence

³ Relationship

⁴ Combination

روش مبتنی بر تطابق

هدف، ساخت دسته‌بند با یافتن شباهت‌های موجود بین دسته‌بند یک در مقابل بقیه هر کلاس و ضابطه آن کلاس است. ضابطه هر کلاس یک نمایش و توصیفی از کلاس است و یافتن شباهت و تطابق بین آن و دسته‌بندی مربوط به آن کلاس به تولید دسته‌بند اصلی منجر می‌شود. برای داده‌های دیده نشده با استفاده از ضابطه کلاس و تابع تطابق یافت شده یک دسته‌بند ساخته می‌شود و کلاس جدید دسته‌بندی می‌شود.

نقطه قوت این روش ارتباطات بر پایه تابع تطابق است که به راحتی قابل یافتن است اما نقطه ضعف این روش این است که این ارتباطات را به طور صریح و واضح بیان نمی‌کند.

میتنی بر ارتباط

هدف، ساخت دسته‌بند بر اساس ارتباط بین کلاس‌هاست. برای یافتن ارتباط میان کلاس‌های دیده‌شده و دیده‌نشده می‌توان از ارتباط بین ضابطه کلاس‌ها و یا هر ارتباط مناسب دیگری استفاده کرد. برای کلاس‌های دیده‌نشده با استفاده از ارتباط موجود و دسته‌بند کلاس‌های دیده‌شده یک دسته‌بند برای هر کلاس دیده‌نشده ساخته می‌شود. از دسته‌بندی کلاس‌های دیده‌شده می‌توان در مسائل دیگر نیز استفاده کرد و هزینه آموزش مدل را کاهش داد؛ اما، روابط بین کلاس‌ها از فضای معنایی به فضای ویژگی به طور مستقیم منتقل می‌شود که حل مسئله سازگاری از فضای معنایی به فضای ویژگی مشکل است.

مبتنی بر ترکیب

در این روش هر کلاس را ترکیبی از چند عنصر در نظر می‌گیریم که این عناصر در فضای معنایی وجود دارند. در حقیقت برای استفاده باید از فضاهای دودویی استفاده کرد که فضاهای معمول استفاده شده فضاهای مهندسی شده هستند. روش ساخت دسته‌بند برای کلاس‌های دیده‌نشده بدین صورت است که برای هر یک از عناصر سازنده کلاس‌ها دسته‌بند ساخته شده‌است سپس از آن دسته‌بندها برای ساخت دسته‌بند کلاس جدید استفاده می‌کنیم.

همانند روش قبل می‌توان از دسته‌بندی‌های مورد استفاده در مسائل دیگر نیز استفاده کرد؛ اما، بهینه‌سازی مسئله دو مرحله‌ای آموزش دسته‌بند مشخصه و استنتاج از مشخصه به کلاس دشوار است.

۴-۲-۲ روش‌های برپایه نمونه

هدف در این روش‌ها ایجاد نمونه برچسب‌خورده برای کلاس‌های دیده نشده است. با استفاده از این نمونه‌ها دسته‌بند اصلی آموزش می‌بیند. با توجه به تفاوت در نحوه و منبع تولید نمونه، این روش‌ها به سه زیر دسته مبتنی بر تصویر کردن^۱، مبتنی بر قرض نمونه^۲ و مبتنی بر سنتز^۳ تقسیم می‌شوند.

مبتنی بر تصویر کردن

تولید نمونه برای کلاس دیده‌نشده از طریق تصویرکردن نمونه‌های موجود در فضای ویژگی و ضابطه‌های موجود در فضای معنایی، به یک فضای مشترک انجام می‌شود. در فضای ویژگی با استفاده از دسته‌بند می‌توان داده‌های آزمایش را دسته‌بندی کرد. این ویژگی‌ها فقط برای داده‌های آزمایشی موجود هستند. فضای معنایی شامل ضابطه‌هایی است که هم شامل داده‌های جدید و هم شامل داده‌های آزمایش می‌شوند. می‌بایست یک ارتباط بین فضای ویژگی و فضای معنایی پیدا کنیم و با انتقال هر دو فضا و تصویر کردن در یک فضای سوم از ضابطه‌های موجود به عنوان نمونه کلاس‌های دیده نشده استفاده کنیم. با توجه به اینکه با این روش برای هر کلاس دیده‌نشده یک نمونه تولید می‌شود و فرآیند دسته‌بندی دشوار می‌شود می‌توان از روش‌های ناپارامتری مانند روش KNN استفاده کرد تا بتوان دسته‌بندی بهتری داشت.

انتخاب تابع نگاشت انعطاف پذیر است و با توجه به شرایط مسئله می‌توان دادگان مناسب انتخاب کرد؛ اما، چون برای هر کلاس دیده‌نشده یک نمونه برچسب زده وجود دارد ناچار به استفاده از روش‌های ناپارامتری می‌شویم.

¹Projection

²Instance-borrowing

³Synthesizing

مبتنی بر قرض نمونه

در این روش بر اساس شباهت‌های بین کلاس‌های دیده شده و دیده نشده برای کلاس‌های دیده نشده از کلاس‌های دیده شده نمونه قرض می‌گیریم؛ برای مثال: اگر تا کنون کلاس یوزپلنگ را ندیده‌ایم می‌توانیم از کلاس پلنگ و ببر نمونه قرض بگیریم و برای آموزش کلاس یوزپلنگ از این نمونه‌ها استفاده کنیم. این نمونه‌ها به طور کامل مانند نمونه اصلی نیستند اما به دلیل شباهت‌هایی که دارند می‌توانند برای استفاده مناسب باشند.

به دلیل گستردگی نمونه‌های قرض داده شده می‌توان مدل‌های دسته‌بندی نظارت شده مختلفی را استفاده کرد؛ اما، چون نمونه‌ها همان نمونه‌های کلاس‌های دیده شده هستند باعث می‌شود تا دقت پایینی در دسته‌بندی داشته باشیم.

مبتنی بر سنتز

در این روش برای هر کلاس دیده نشده یک سری نمونه برچسب خورده می‌سازیم و با استفاده از آن‌ها کلاس‌های دیده نشده را آموزش می‌دهیم. در حقیقت پس از ساخت نمونه برای همه کلاس‌ها مسئله به یک مسئله یادگیری ماشین نظارت شده می‌شود. برای تولید داده مصنوعی روش‌های متعددی وجود دارد؛ برای مثال: اگر فرض کنیم که کلاس‌ها از یک توزیع خاص تبعیت می‌کنند با استفاده از حدس پارامترهای آن توزیع برای کلاس‌های دیده نشده می‌توان داده‌های مصنوعی تولید کرد.

از دیگر روش‌ها می‌توان به شبکه‌های مولد متخاصمی یا GAN^۱ اشاره کرد. این شبکه‌ها از دو شبکه ساخته شده‌اند که یکی وظیفه تولید داده و دیگری وظیفه صحت سنجی داده را دارد تا داده تولید شده به داده اصلی شبیه تر باشد. این شبکه‌ها در تولید داده مصنوعی از روش‌های دیگر از عملکرد و دقت بالاتری برخوردار هستند. استفاده از شبکه‌های GAN، یکی از روش‌های مرسوم برای تولید تصاویر جعلی برای دور زدن فرآیند احراز هویت سیستم‌های تشخیص چهره و گرفتن دسترسی از سیستم است.

^۱Generative Adversarial Networks

به دلیل گستردگی نمونه‌های تولید شده می‌توان مدل‌های دسته‌بندی نظارت شده مختلفی را استفاده کرد؛ اما، چون نمونه‌های تولید شده به طور معمول از توزیع نرمال پیروی می‌کنند. می‌تواند باعث سوگیری مدل تولید شده شود.

در خارج از شرایط آزمایشگاهی کلاس‌های دیده‌شده و دیده‌نشده در ترکیب با هم هستند و به این سادگی نمی‌توان آن‌ها را جدا از هم در نظر گرفت به همین دلیل می‌حث یادگیری بدون نمونه تعمیم یافته^۱ مطرح می‌شود. در حل این نوع مسائل روش‌های یاد شده لزوماً نتیجه مناسبی نمی‌دهند و باید به دنبال روش‌های بهتر بود.

۵-۲-۲ یک مثال

روش‌ها و فضاها ی یادگیری در یادگیری بدون نمونه در این فصل بررسی شد در ادامه یک مثال از یادگیری بدون نمونه برای دسته‌بندی حیوانات را برای فهم بهتر بررسی می‌کنیم.

مدل‌های مختلف که بر پایه روش یادگیری بدون نمونه ارائه شده‌اند می‌توانند ترکیبی از روش‌ها و فضاها را داشته باشند و یا فقط متکی بر یکی از آن‌ها طراحی شده باشند. به عنوان مثال در مقاله [۲] از فضای مشخصه استفاده کرده‌است و سعی کرده با ارائه دو روش برای یادگیری حیوانات مختلف را دسته‌بندی کند. مقاله از سه روش برای دسته‌بندی نام برده‌است و آن‌ها را با یکدیگر مقایسه می‌کند. دسته‌بندی چندکلاسه مسطح^۲، پیش‌بینی مشخصه به طور مستقیم^۳ و پیش‌بینی مشخصه به طور غیر مستقیم^۴ به طور شهودی این سه روش در شکل ۲-۳ نشان داده شده‌اند. به دلیل این‌که همواره نمی‌توان پایگاه داده‌ای کامل و برچسب خورده داشت نیازمند راهکارهایی هستیم تا تلاش انسان در جمع‌آوری و دسته‌بندی داده‌ها را کم کنیم.

در شکل ۲-۳ تصویر الف، نشان دهنده روش اول است. در این روش ماشین یک بردار ثابت را یاد می‌گیرد. x ورودی مسئله، y برچسب داده‌ها آزمایش و z برچسب داده‌هایی است که نیاز داریم آن‌ها را بیابیم. چون فرآیند

¹Generalized zero-shot learning

²flat multi-class classification

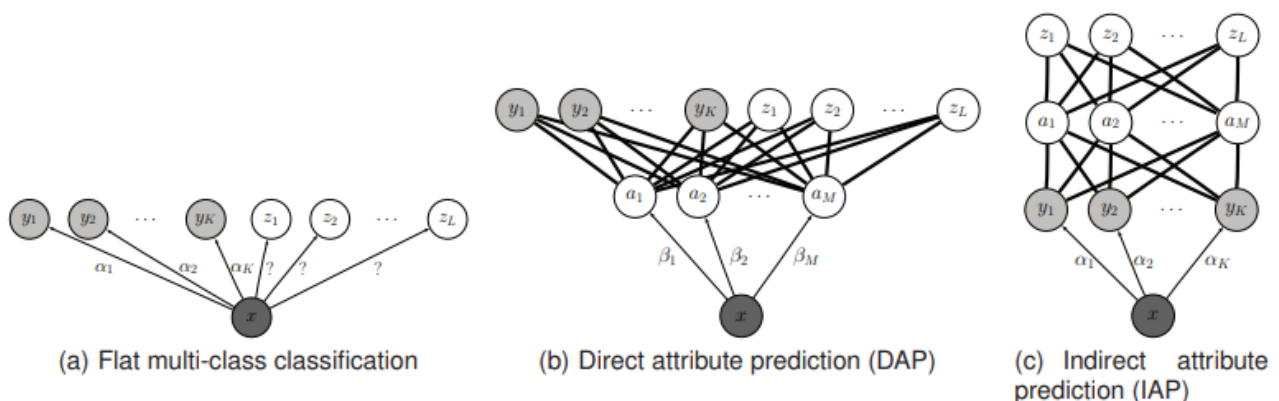
³direct attribute prediction

⁴indirect attribute prediction

یادگیری y هیچ تاثیری بر فرآیند یادگیری z ندارد پس از یادگیری‌های قبلی برای پیش بینی نمی‌توان استفاده کرد و این روش یک روش یادگیری معمولی است که قبلاً نیز استفاده می‌شد و برای یادگیری z نیازمند داده‌های ورودی هستیم که با توجه به اینکه به دنبال یادگیری بدون نمونه هستیم این روش مناسب نیست.

راهکار ارائه شده برای یادگیری استفاده از ویژگی‌های معنایی سطح بالایی هستند که هرکدام برای انسان معنای خاصی دارند. این مشخصه‌ها، ویژگی‌های قابل نام‌گذاری هستند؛ مانند: رنگ، شکل، طرح بدن و عادات غذایی. استفاده از این مشخصه‌ها به ما کمک می‌کند تا نقش انسان را در فرآیند یادگیری کمتر کنیم و نیاز کمتری به ویژگی‌های سطح پایین تصویر داشته باشیم.

این مشخصه‌ها را می‌توان همراه با تصاویر یا همراه با دسته‌بندی‌های تصاویر در نظر گرفت و این ویژگی باعث شده است تا فرآیند دسته‌بندی بر اساس مشخصه‌ها^۱ توسط مقاله معرفی شود. در این فرآیند با توجه به اینکه دسته‌های آموزش و آزمایش جدا از هم هستند و به یکدیگر وابسته نیستند؛ می‌توان با استفاده از این صفات و انتقال یادگیری^۲، بین داده‌های آموزشی، داده‌های آزمایشی را دسته‌بندی کرد. در شکل ۲-۲ می‌توانید نحوه دسته‌بندی بر اساس صفات را مشاهده کنید. با توجه به توضیحات ارائه شده به سراغ توضیح دو روش دیگر می‌رویم.



شکل ۲-۳: روش‌های دسته‌بندی [۲]

^۱attribute-based classification

^۲transfer learning

در روش پیش‌بینی مشخصه به صورت مستقیم^۱ یا DAP در مرحله آموزش کلاس خروجی هر نمونه (x) برای لایه مشخصه‌ها نیز به طور قطع یک برچسب (y) مشخص می‌کند. متعاقباً می‌توان از هر روش با نظارتی استفاده کرد و پارامترهای هر مشخصه β_m را پیدا کرد. این بدین معنی است که فرآیند یادگیری اولیه برای یادگیری مشخصه‌ها متناسب با هر نمونه و دسته‌بندی مشخصه‌ها و نمونه‌ها را می‌توان با یک روش یادگیری نظارتی ساده انجام داد. حال با استفاده از یادگیری انتقالی و استفاده از شبکه‌ای که از پیش نمونه‌ها و مشخصه‌ها آن دسته‌بندی شده‌اند برای نمونه‌های جدید که از پیش دیده نشده‌اند (داده‌های آزمون) دسته‌بندی جدیدی را فقط بر اساس لایه مشخصه‌ها وزن‌ها یا پارامترهایی که شبکه تا به حال دارد و به لایه مشخصه‌ها اختصاص داده‌است، استفاده کرد و داده جدید را دسته‌بندی کرد.

در روش پیش‌بینی مشخصه به صورت غیر مستقیم^۲ یا IAP همانند روش قبل از مشخصه‌ها برای انتقال دانش بین دسته‌ها استفاده می‌کند اما اینبار مشخصه‌ها بین دو لایه از برچسب‌ها قرار دارند. یک لایه برچسب‌هایی که در لایه آموزش اختصاص می‌یابند (y) و یک لایه برچسب‌هایی که باید به داده‌های جدید اختصاص پیدا کنند (z). در مرحله آموزش پارامترهای لایه مشخصه‌ها توسط برچسب‌های آموزش مقدار دهی می‌شوند همانند یک مسئله دسته‌بندی چندکلاسه که می‌توان با یک روش نظارتی ساده نیز یادگیری را انجام داد. در مرحله آزمایش با استفاده از مقادیری که به لایه مشخصه‌ها اختصاص داده‌شده دسته‌بندی داده‌های آزمایش را صورت می‌گیرد. استفاده از لایه مشخصه‌ها به برای دسته‌بندی داده‌های آزمایش این امکان را می‌دهد تا بتوانیم عملیاتی مشابه تنظیم^۳ را انجام دهیم و فقط ترکیبات با معنی از مشخصه‌ها را ایجاد کنیم.

روش‌های یاد شده یک سری استراتژی کلی محسوب می‌شوند که می‌توانند با ترکیبی از روش‌های موجود مانند: یادگیری با نظارت یا رگرسیون‌ها بر روی مشخصه‌ها تصاویر یا دسته‌های تصاویر با استفاده از پارامترهای

¹direct attribute prediction

²indirect attribute prediction

³regularization

پیش‌بینی شده انجام شوند. در این مقاله از روش توزیع‌های احتمالاتی استفاده شده و مشخصه‌های استفاده شده را مشخصه‌هایی بله یا خیر در نظر گرفته‌است. برای مشخصه‌هایی که بله یا خیر نیستند می‌توان به جای دسته‌بندی از رگرسیون استفاده کرد.

در روش DAP برای دسته‌بندی کردن تصاویر آزمون، احتمال قطعی به دست خواهد آمد زیرا در مرحله آموزش لایه مشخصه‌ها مقادیر مناسب را اتخاذ می‌کنند و از همین مقادیر برای تصاویر آزمون نیز استفاده می‌شود. به زبان ریاضی معادلات زیر صادق است.

$$p(z|x) = \sum_{a \in (0,1)^M} p(z|a)p(a|x) \frac{p(z)}{p(a^a)} \prod_{m=1}^M p(a_m^z|x). \quad (۱-۲)$$

$$f(x) = \operatorname{argmax}_{l=1,\dots,L} p(z=l|x) = \operatorname{argmax}_{l=1,\dots,L} \prod_{m=1}^M \frac{p(a_m^{z_l}|x)}{p(a_m^{z_l})}. \quad (۲-۲)$$

در روش IAP لایه مشخصه‌ها نقش یک تنظیم‌کننده را ایفا می‌کند پس به طور قطع نمی‌توان برای تشخیص لایه آزمون استفاده کرد و می‌بایست با استفاده از روابط احتمال یک احتمال میانی را حساب کرد و پس از آن از رابطه ۲-۲ استفاده کرد.

$$p(a_m|x) = \sum_{k=1}^K p(a_m|y_k)p(y_k|x). \quad (۳-۲)$$

سه بانک اطلاعاتی استفاده شده است. در ادامه هر یک را توضیح می‌دهیم. ۱-۲

Animal with Attributes

این بانک اطلاعاتی به عنوان بانک اصلی استفاده شده است. این بانک شامل ۵۰ کلاس حیوانات و ۸۵ کلاس مشخصه‌های معنایی است؛ از این تعداد ۴۰ کلاس به عنوان داده‌های آموزشی و ۱۰ کلاس به عنوان داده‌های

آزمایش استفاده شده است. تقسیم بندی به صورت تصادفی نیست اما سعی شده است تا توزیع داده ها در هر دو دسته آزمایش و آزمون به طور مناسبی صورت شود.

در کل ۳۰۴۷۵ عکس در این بانک داده وجود دارد که تعداد تصاویر برای دسته های مختلف حیوانات متفاوت می باشد. برای تسريع در محاسبات یک سری از ویژگی های تصاویر مانند: جنبه های رنگ، بافت و شکل، هیستوگرام رنگ و سایر ویژگی های مهم تصویر نیز به پایگاه داده اضافه شده و برای آموزش از روش 5 fold cross-validation استفاده شده است.

aPascal-aYahoo

این بانک شامل دو دسته داده یکی داده های بانک داده PASCAL و دیگری داده هایی که از موتور جستجوی Yahoo استخراج شده است. ۲۰ کلاس داده در PASCAL و ۱۲ کلاس داده در Yahoo و دسته بندی داده ها در هر یک با دیگری متفاوت است پس می توان از داده های PASCAL برای آموزش و از داده های Yahoo برای آزمون استفاده کرد. هر تصویر ۶۴ مشخصه ها دودویی را شامل می شود و همانند بانک داده قبلی برای تسريع در محاسبات یک سری از ویژگی های تصاویر از قبل محاسبه شده اند.

SUN Attributes

این بانک زیر مجموعه ای از بانک داده SUN Database که شامل ۷۱۷ کلاس داده و هر تصویر شامل ۱۰۲ مشخصه دودویی است. این مشخصه ها شامل توضیفات صحنه، شرایط نورپردازی، مواد داخل تصویر و ... است.

جدول ۱-۲: بانک های اطلاعاتی [۲]

SUN	aP/aY	AwA	Dataset
۱۴۳۴۰	۱۵۳۳۹	۳۰۴۷۵	# Images
۷۱۷	۳۲	۵۰	# Classes
۱۰۲	۶۴	۸۵	# Attributes
image per binary	image per binary	class per both	Annotation Level (real- Type Annotation binary) or valued

برای ارزیابی از ماشین بردار پشتیبان^۱ یا SVM استفاده شده است. برای روش مستقیم از یک SVM غیر خطی و برای روش غیرمستقیم از نوع one-versus-rest استفاده شده است. نتایج به دست آمده را در جداول ۲-۲ و ۲-۳ مشاهده می کنید.

جدول ۲-۲: تقسیم بندی پیش فرض داده ها [۲]

rnd	CT-H	CT-cc	IAP	DAP	method
۰.۱۰	30.8 ± 0.2	30.7 ± 0.2	۲.۴۲	۴.۴۱	MC acc.
۰.۵۰	۴.۷۳	۴.۷۳	۰.۸۰	۴.۸۱	classAUC
۰.۵۰	—	—	۱.۷۲	۸.۷۲	attrAUC

جدول ۲-۳: تقسیم بندی داده ها به صورت تصادفی [۲]

md	CT-H	CT-cc	LAP	DAP	method
۰.۱۰	27.3 ± 4.0	27.7 ± 4.3	34.1 ± 5.1	37.1 ± 3.9	MC acc.
۰.۵۰	72.8 ± 3.1	72.4 ± 2.7	76.3 ± 5.5	80.4 ± 3.1	classAUC
۰.۵۰	—	—	69.7 ± 3.8	70.7 ± 3.5	attrAUC

در روش مستقیم برای بدست آوردن مقادیر مناسب کرنل از SVM منحنی ROC^۲ و میانگین سطح زیر منحنی^۳ برای صفات و روش 5 fold cross-validation استفاده شده است.

منحنی یاد شده، یک نمودار برای نمایش توانایی ارزیابی یک سیستم دسته بندی دودویی محسوب می شود که آستانه تشخیص آن نیز متغیر است. که با ترسیم نسبت نرخ مثبت صحیح^۴ که به اختصار TPR نامیده می شود برحسب نرخ مثبت کاذب^۵ با نام اختصاری FPR ایجاد می شود.

در روش غیر مستقیم مراحل مانند روش قبل است با این تفاوت که میانگین سطح زیر منحنی بر روی پیش بینی کلاس ها استفاده شده است.

همان طور که در شکل ۲-۴ مشاهده می کنید. دقت روش در تشخیص برخی از دسته ها مانند نهنگ های کوهان دار دقت بالایی همانند روش های یادگیری با نظارت دارد؛ اما در مورد دسته بندی هایی مانند خوک ها و


¹Support Vector Machine

²Receiver Operation Characteristic

³AUC

⁴True Positive Rate

⁵False Positive Rate



شکل ۲-۴: منحنی [۲ROC]

پاندهای بزرگ دقت خیلی پایینی دارد. یکی از دلایل این اتفاق شباهتهایی است که در این دسته‌ها رخ می‌دهد؛ به طور مثال: ظاهر پاندهای بزرگ، خوک‌ها و اسب‌های آبی.

به طور مشابه بر روی دو پایگاه داده دیگر نیز بررسی‌ها انجام شده‌است و نتایج را در جداول ؟؟ و ؟؟ مشاهده

می‌کنید.

جدول ۲-۴: تقسیم بندی پیش‌فرض داده‌ها برای [۲aPascal-aYahoo]

rnd	CT-H	IAP	DAP-C	DAP-I	method
۳.۸	16.7 ± 0.5	۹.۱۶	۱.۱۹	۸.۱۶	MC acc.
۰.۵۰	۲.۶۴	۴.۷۵	۵.۷۶	۹.۷۶	classAUC
۰.۵۰	—	۱.۷۳	۷.۷۳	۶.۷۰	attrAUC

جدول ۲-۵: تقسیم بندی داده‌ها برای sub [۲attributes]

rnd	CT-H	IAP	DAP-C	DAP-I	method
۴.۱	12.9 ± 1.3	18.0 ± 1.5	22.2 ± 1.6	18.1 ± 1.2	MC acc.
۲.۶	32.6 ± 2.0	41.1 ± 2.1	46.6 ± 1.7	40.2 ± 2.1	level2 acc.
۳.۳۳	74.2 ± 2.0	82.1 ± 2.5	85.7 ± 2.1	74.2 ± 4.0	level1 acc.
۰.۵۰	77.1 ± 0.0	87.9 ± 0.7	92.3 ± 0.7	90.5 ± 0.7	class mAUC
۰.۵۰	—	82.7 ± 0.8	83.9 ± 0.8	82.0 ± 0.6	attrAUC

۲-۳ شبکه‌های GAN و روش‌های حمله

در یادگیری ماشین دو دسته مدل وجود دارند، دسته اول مدل‌های جداساز^۱ و دسته دوم مدل‌های مولد می‌باشند. در مدل‌های جداساز هدف دسته‌بندی و متمایز ساختن کلاس‌هاست، درحالی‌که در مدل‌های مولد توزیع داده‌ها محاسبه و تخمین زده می‌شود، سپس با استفاده از پارامترهای بدست آمده برای توزیع کلاس‌ها دسته‌بندی می‌شوند. علاوه بر دسته‌بندی، می‌توان برای هر کلاس و توزیع داده جدید تولید کرد. GAN یک شبکه مولد است که می‌توان از آن برای تولید تصاویر ساختگی که در عین واقعی و طبیعی بودن هرگز وجود نداشته‌اند استفاده کرد. این شبکه شامل دو بخش است، یک بخش مولد و دیگری جداساز. بخش مولد تصویر را تولید و بخش جداساز آن را تشخیص می‌دهد که واقعی است یا غیر واقعی و در صورت تشخیص غیر واقعی دوباره وزن‌های شبکه مولد به‌روزرسانی شده و تصویر جدیدی تولید می‌شود و این کار تا جایی ادامه پیدا می‌کند که شبکه جداساز به طور تقریباً برابر تشخیص واقعی و غیر واقعی بدهد و در دسته‌بندی تصویر تولیدی عاجز شود. [۴]

۲-۴ جمع‌بندی

در بخش اول یادگیری با یک نمونه بررسی شد و شبکه سیامی که یکی از شبکه‌های پر کاربرد در تشخیص چهره است معرفی شد. در بخش دوم با یک مثال و بررسی‌های کلی در مورد یادگیری بدون نمونه سعی کردیم تا به طور کلی با این روش آشنا شویم. کاربرد روش بدون یادگیری بسیار گسترده‌است و از کاربردهای آن می‌توان به استفاده در تشخیص حرکت در ویدیو و جلوگیری از جعل هویت اشاره کرد. در بخش سوم کمی شبکه GAN را توضیح دادیم و چند مورد از حملات به سیستم‌های تشخیص چهره را توضیح دادیم. در ادامه و در فصل بعد کارهای مرتبط با جلوگیری از جعل تصویر چهره و حملات به این سیستم‌ها را بررسی می‌کنیم.

^۱Discriminative

فصل سوم

کارهای مرتبط

فصل چهارم

روش پیشنهادی

فصل پنجم

پیاده‌سازی

فصل ششم

ارزیابی کارایی

فصل هفتم

جمع بندی و نتیجه گیری

References

- [1] G. Koch, R. Zemel, and R. Salakhutdinov, “Siamese Neural Networks for One-shot Image Recognition,” tech. rep., 2015.
- [2] C. H. Lampert, H. Nickisch, and S. Harmeling, “Attribute-based classification for zero-shot visual object categorization,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 36, pp. 453–465, mar 2014.
- [3] W. Wang, V. W. Zheng, H. Yu, and C. Miao, “A Survey of Zero-Shot Learning,” *ACM Transactions on Intelligent Systems and Technology*, vol. 10, pp. 1–37, jan 2019.
- [4] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative Adversarial Networks,” *Communications of the ACM*, vol. 63, pp. 139–144, jun 2014.